

Proposal Skripsi



Sistem Deteksi Intrusi Jaringan Komputer Menggunakan
Temporal Fusion Transformer dengan Integrasi Skor Anomali
Isolation Forest

Diajukan oleh

Fahri Desrian

(2206048726, fahri.desrian@sci.ui.ac.id)

Dosen Pembimbing

Prof. Dr. Drs. Suryadi, M.T.

Program Studi Sarjana Matematika

Departemen Matematika FMIPA UI

Depok, Mei 2026

Lembar Persetujuan

Proposal Skripsi ini telah disetujui oleh Pembimbing I Proposal Skripsi untuk dinilai oleh dosen penguji proposal skripsi.

Depok, 29 Mei 2026

Pembimbing I Proposal Skripsi

(Prof. Dr. Drs. Suryadi, M.T.)

Lembar Pernyataan Penggunaan Kecerdasan Artifisial

Saya menyatakan bahwa dalam penyusunan Proposal Skripsi ini, saya menggunakan teknologi Kecerdasan Buatan dengan *platform* ChatGPT dan Claude untuk tujuan *brainstorming* serta membenarkan format latex yang kurang rapi dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Proposal Skripsi ini.

Nama : Fahri Desrian

NPM : 2206048726

Tanda Tangan :



Tanggal : 28 Mei 2026

Ringkasan Proposal Skripsi

1 Sistem deteksi intrusi jaringan komputer merupakan hal penting dan mendesak dalam
2 keamanan siber modern, namun sebagian besar sistem yang ada baru memberikan peringatan
3 setelah serangan terjadi sehingga jendela waktu mitigasi menjadi sangat terbatas. Untuk
4 mengatasi keterbatasan ini, dibutuhkan pendekatan yang mampu memanfaatkan pola tem-
5 poral lalu lintas jaringan komputer guna memberikan indikasi serangan lebih awal, sebelum
6 dampaknya meluas. Penelitian ini bertujuan merancang dan mengevaluasi pendekatan sis-
7 tem deteksi intrusi jaringan komputer berbasis pola temporal yang menggabungkan skor
8 anomali dari *Isolation Forest* (IF) sebagai fitur tambahan dalam model *Temporal Fusion*
9 *Transformer* (TFT). IF berperan mengukur tingkat ketidaknormalan setiap titik data ber-
10 dasarkan kemudahan isolasinya dari populasi, sementara TFT dipilih untuk memodelkan
11 deret waktu multivariat dan menangkap dependensi temporal jangka panjang secara inter-
12 pretatif. Pendekatan ini memperlakukan data lalu lintas jaringan komputer sebagai deret
13 waktu dengan menggunakan teknik *sliding window* berparameter panjang historis W dan
14 panjang jendela target T , sehingga urutan W rekaman lalu lintas yang telah diamati digu-
15 nakan untuk memodelkan dinamika temporal dan menghasilkan indikasi status lalu lintas
16 pada T titik waktu berikutnya. Skor anomali yang dihasilkan IF untuk setiap titik waktu
17 kemudian diintegrasikan sebagai fitur tambahan dalam input TFT, sehingga model tidak
18 hanya mempelajari pola temporal dari fitur jaringan komputer mentah, tetapi juga mem-
19 pertimbangkan derajat ketidaknormalan pada setiap titik waktu secara bersamaan. Peman-
20 faatan skor anomali sebagai fitur tambahan dalam model deret waktu berbasis Transformer
21 untuk sistem deteksi intrusi masih relatif terbatas, sehingga penelitian ini berupaya mengisi
22 celah tersebut. Penelitian ini menggunakan dataset UNSW-NB15 yang dikembangkan oleh
23 Australian Centre for Cyber Security di University of New South Wales sebagai data utama,
24 mengingat dataset ini memiliki informasi cap waktu yang memungkinkan pengurutan reka-
25 man secara kronologis untuk membentuk representasi deret waktu. Dataset tersebut terdiri
26 dari sekitar 2,5 juta rekaman dengan 49 atribut, termasuk atribut lalu lintas jaringan kom-
27 puter dan label kelas, serta mencakup sembilan kategori serangan di samping lalu lintas
28 normal. Namun, eksperimen dalam penelitian ini dibatasi pada empat kelas, yaitu Nor-
29 mal, Generic, Exploits, dan Fuzzers, dengan pertimbangan representativitas distribusi kelas
30 dan stabilitas proses pelatihan. Evaluasi performa model dilakukan menggunakan metrik
31 akurasi, presisi, recall, F1-score, dan tingkat alarm palsu dalam skenario klasifikasi multi-
32 kelas. Selain itu, interpretasi peran skor anomali dilakukan untuk memahami kontribusi IF
33 dalam membedakan kategori serangan dari lalu lintas normal. Penelitian ini berhipotesis
34 bahwa integrasi skor anomali IF sebagai fitur tambahan dalam TFT dapat meningkatkan
35 performa deteksi intrusi dibandingkan model TFT tanpa fitur anomali, khususnya dalam
36 mengenali pola serangan yang tidak normal pada data deret waktu lalu lintas jaringan kom-
37 puter. Oleh karena itu, evaluasi dilakukan melalui perbandingan antara model TFT tanpa
38 skor anomali IF dan model TFT dengan integrasi skor anomali IF.

39 **Kata kunci:** *deep learning, intrusion detection system, cybersecurity, Isolation Forest, Tem-*
40 *poral Fusion Transformer*

1 Pendahuluan

Perkembangan teknologi digital yang berlangsung secara masif dalam dua dekade terakhir telah membawa transformasi mendasar pada hampir seluruh sektor kehidupan, mulai dari layanan keuangan hingga infrastruktur kritis negara. Seiring dengan meningkatnya ketergantungan terhadap infrastruktur digital, ancaman kejahatan siber turut meningkat dengan intensitas yang mengkhawatirkan. FBI's Internet Crime Complaint Center mencatat kerugian sebesar 10,3 miliar dolar AS pada tahun 2022 dengan lebih dari 800 ribu laporan insiden. Selain itu, rata-rata biaya per pelanggaran data secara global mencapai USD 4,45 juta pada tahun 2023 (Kuzior et al., 2024). Di tingkat nasional, BSSN mencatat total trafik anomali terkait serangan siber di Indonesia sepanjang tahun 2024 mencapai 330.527.636 anomali, dengan 514.508 aktivitas ransomware dan 26.771.610 aktivitas phishing yang teridentifikasi, sementara penelusuran pada darknet mengungkap 56.128.160 temuan data exposure yang berdampak pada 461 instansi di Indonesia (Badan Siber dan Sandi Negara (BSSN) / Id-SIRTII/CC Direktorat Operasi Keamanan Siber, 2024). Kondisi ini menegaskan bahwa ancaman siber telah menjadi tantangan strategis yang memerlukan penanganan yang sistematis dan berbasis pendekatan ilmiah yang mutakhir (Sviatun et al., 2021).

Sebagai respons terhadap meningkatnya ancaman intrusi pada jaringan komputer, konsep Intrusion Detection System (IDS) diperkenalkan sebagai mekanisme untuk memantau dan mendeteksi aktivitas mencurigakan. Gagasan awal IDS dikemukakan oleh Anderson pada tahun 1980 melalui konsep pemantauan aktivitas sistem untuk mengidentifikasi penyalahgunaan dan akses tidak sah terhadap sumber daya komputasi (James & Co, 1980). Secara umum, IDS diklasifikasikan menjadi Host-based IDS (HIDS) yang berfokus pada pemantauan aktivitas pada satu perangkat, dan Network-based IDS (NIDS) yang memantau lalu lintas jaringan komputer secara keseluruhan. Seiring dengan berkembangnya arsitektur jaringan komputer yang semakin kompleks dan terdistribusi, kebutuhan akan pemantauan pada level jaringan komputer menjadi semakin penting, sehingga NIDS menjadi pilihan yang lebih relevan karena kemampuannya memberikan visibilitas jaringan komputer secara menyeluruh dan mendeteksi serangan secara lebih cepat tanpa bergantung pada satu titik pantau. Namun demikian, meningkatnya kompleksitas pola serangan menuntut pengembangan sistem deteksi intrusi yang lebih adaptif dan cerdas.

Meskipun NIDS telah berkembang pesat, pendekatan deteksi berbasis tanda tangan (*signature-based*) yang menjadi fondasi sistem berbasis tanda tangan tradisional masih memiliki keterbatasan mendasar. Sistem ini hanya mampu mengenali serangan yang polanya telah diketahui dan tersimpan dalam basis data tanda tangan (Kothamali & Banik, 2022). Selain itu, pendekatan berbasis tanda tangan juga memiliki keterbatasan dalam mendeteksi serangan baru maupun varian serangan yang belum pernah terlihat (Chinnasamy et al., 2025). Akibatnya, serangan baru (*zero-day attack*) maupun varian serangan yang dimodifikasi secara minor berpotensi tidak terdeteksi oleh sistem ini. Keterbatasan tersebut mendorong pengembangan pendekatan berbasis anomali (*anomaly-based detection*), yang memungkinkan sistem mempelajari pola lalu lintas normal dan mengidentifikasi penyimpangan dari pola tersebut sebagai potensi ancaman. Pendekatan ini menjadi dasar bagi pemanfaatan metode pembelajaran mesin dalam sistem deteksi intrusi modern.

Pengembangan pendekatan berbasis anomali tersebut membuka ruang bagi penerapan *machine learning* (ML) dan *deep learning* (DL) dalam sistem deteksi intrusi, yang dalam

85 beberapa tahun terakhir telah menunjukkan kemajuan signifikan. Tinjauan sistematis ter-
86 hadap metode *deep learning* untuk NIDS mencatat bahwa berbagai arsitektur telah diuji-
87 cobakan, seperti *Convolutional Neural Network* (CNN) untuk ekstraksi fitur spasial dan *Long*
88 *Short-Term Memory* (LSTM) untuk pemodelan dependensi sekuensial, serta model hibrid
89 yang menggabungkan keduanya (Chinnasamy et al., 2025). Arsitektur-arsitektur tersebut
90 dilaporkan mampu mencapai tingkat akurasi yang tinggi pada berbagai dataset, termasuk
91 CIC IDS 2017, UNSW-NB15, NSL-KDD, dan WSN-DS. Sejalan dengan itu, pendekatan
92 hibrid yang mengintegrasikan XGBoost, CNN, dan LSTM menunjukkan performa deteksi
93 yang lebih unggul dibandingkan metode tunggal pada dataset-dataset tersebut (Sajid et al.,
94 2024). Meskipun demikian, sebagian besar pendekatan tersebut masih berfokus pada deteksi
95 berdasarkan kondisi lalu lintas yang sedang atau telah diproses, dan belum secara ekspli-
96 sit memanfaatkan struktur temporal data dalam proses deteksi intrusi, sehingga membuka
97 peluang untuk pengembangan pendekatan yang lebih memanfaatkan pola temporal secara
98 eksplisit.

99 Meskipun pendekatan ML dan DL telah meningkatkan akurasi deteksi secara signifikan,
100 sebagian besar sistem yang ada masih memberikan peringatan berdasarkan kondisi lalu lin-
101 tas jaringan komputer yang sedang dianalisis pada saat itu, tanpa mempertimbangkan pola
102 historis yang mendahuluinya. Implikasi operasional dari pendekatan semacam ini cukup
103 serius karena pada saat peringatan diberikan, kerusakan seperti eksfiltrasi data, eskalasi
104 hak akses, atau penyebaran serangan ke bagian lain dalam jaringan komputer dapat saja
105 telah terjadi, sehingga jendela waktu respons menjadi sangat terbatas (Psychogyios et al.,
106 2024). Pendekatan yang lebih ideal adalah sistem yang mampu memanfaatkan pola his-
107 toris lalu lintas jaringan komputer untuk memberikan indikasi serangan lebih awal, sebelum
108 dampaknya meluas. Pendekatan ini tidak dimaksudkan untuk memprediksi waktu pasti ter-
109 jadinya serangan, melainkan memanfaatkan pola temporal dari urutan lalu lintas jaringan
110 komputer yang telah diamati untuk memodelkan kecenderungan status lalu lintas pada
111 horizon pendek. Dengan demikian, sistem diarahkan untuk melakukan klasifikasi temporal
112 berbasis horizon pendek, yaitu mengestimasi status lalu lintas pada beberapa titik waktu
113 target berdasarkan urutan historis yang telah diamati. Namun demikian, penelitian yang
114 secara eksplisit mengadopsi perspektif ini dalam sistem deteksi intrusi masih sangat ter-
115 batas dalam literatur (Psychogyios et al., 2024), sehingga membuka ruang penelitian yang
116 signifikan untuk dieksplorasi.

117 Fondasi dari pendekatan yang memberikan indikasi serangan lebih awal dalam sistem
118 deteksi intrusi terletak pada pemahaman bahwa lalu lintas jaringan komputer memiliki uru-
119 tan kejadian dan keterkaitan waktu. Setiap koneksi atau paket data merupakan bagian dari
120 rangkaian peristiwa yang saling berkaitan, sehingga urutan kemunculannya dapat memuat
121 informasi penting bagi proses deteksi. Representasi data lalu lintas jaringan komputer seba-
122 gai deret waktu multivariat telah digunakan dalam berbagai konteks IDS. Arus paket dalam
123 jaringan komputer dapat dimodelkan sebagai deret waktu berlapis menggunakan *Markov*
124 *Transition Field*, yang menunjukkan bahwa lalu lintas jaringan komputer memiliki karak-
125 teristik temporal dan bahwa model sekuensial seperti LSTM masih memiliki keterbatasan
126 dalam menangkap hubungan jangka panjang antar waktu (Joshi & Gurusamy, 2025). Selain
127 itu, representasi deret waktu memungkinkan model mempertimbangkan perubahan pola lalu
128 lintas dari waktu ke waktu secara eksplisit. Dataset IDS dapat dikonversi ke dalam format
129 deret waktu untuk menangkap pola temporal yang berkaitan dengan kemunculan serangan

130 melalui pendekatan *sliding window* (Psychogyios et al., 2024). Hasil eksperimen pada peneli-
131 tian tersebut menunjukkan bahwa pendekatan berbasis deret waktu mampu mencapai per-
132 forma yang kompetitif dibandingkan klasifikasi berbasis data tabular yang tidak secara eks-
133 plisit membentuk urutan temporal. Secara konseptual, pendekatan ini mengubah fokus dari
134 sekadar menanyakan "apakah serangan sedang terjadi" menjadi "bagaimana pola lalu lintas
135 yang telah diamati berkaitan dengan kemunculan serangan". Namun demikian, pendekatan
136 berbasis deret waktu yang ada masih memiliki keterbatasan dalam menangkap hubungan
137 temporal jangka panjang secara efektif serta dalam memanfaatkan informasi anomali secara
138 eksplisit dalam proses deteksi.

139 Untuk mengatasi keterbatasan model sekuensial seperti LSTM dalam pemodelan deret
140 waktu multivariat jangka panjang, penelitian ini mengadopsi *Temporal Fusion Transformer*
141 (TFT) sebagai model utama dalam pemodelan temporal. TFT merupakan arsitektur yang
142 menggunakan mekanisme *attention* untuk menyoroti bagian data yang paling relevan dalam
143 pemodelan deret waktu multivariat, dengan tetap mempertahankan kemampuan interpretasi
144 terhadap perubahan pola lalu lintas dari waktu ke waktu (Lim et al., 2021). Dibanding-
145 kan dengan model berbasis LSTM, TFT memiliki keunggulan dalam menangkap hubungan
146 jangka panjang antar waktu serta dalam mengelola berbagai jenis input yang heterogen
147 secara simultan tanpa memerlukan asumsi awal mengenai hubungan antar variabel. Ke-
148 mampuan ini menjadi relevan dalam konteks lalu lintas jaringan komputer yang memiliki
149 banyak fitur dengan karakteristik temporal yang berbeda-beda. Selain itu, TFT dilengkapi
150 dengan mekanisme seleksi variabel dan *attention* temporal yang memungkinkan identifikasi
151 fitur serta pola waktu yang paling berpengaruh terhadap hasil klasifikasi, sehingga tidak
152 hanya berfungsi sebagai model, tetapi juga sebagai alat analisis terhadap perilaku serangan
153 dalam jaringan komputer (Lim et al., 2021).

154 Meskipun *Temporal Fusion Transformer* mampu memodelkan perubahan pola lalu lintas
155 dari waktu ke waktu secara mendalam, informasi eksplisit mengenai tingkat anomali suatu
156 sampel tidak secara langsung tersedia dari data mentah. Untuk menjembatani keterbatasan
157 ini, penelitian ini mengintegrasikan *Isolation Forest* sebagai penghasil skor anomali yang
158 digunakan untuk memperkaya representasi fitur sebelum diproses oleh model. *Isolation*
159 *Forest* merupakan metode deteksi anomali yang bekerja dengan prinsip isolasi, di mana data
160 yang bersifat berbeda dan jarang muncul cenderung lebih mudah dipisahkan dari mayoritas
161 data (Liu et al., 2008). Berdasarkan prinsip tersebut, setiap sampel dapat diberikan skor
162 yang merepresentasikan tingkat ketidaknormalannya. Dalam penelitian ini, skor anomali
163 tersebut tidak digunakan sebagai hasil klasifikasi akhir, melainkan sebagai fitur tambahan
164 yang digabungkan dengan fitur temporal lainnya dalam sekuens input. Dengan demikian,
165 model tidak hanya mempelajari pola temporal dari lalu lintas jaringan komputer, tetapi juga
166 memperoleh informasi eksplisit mengenai tingkat ketidaknormalan pada setiap titik waktu.
167 Integrasi ini diharapkan mampu meningkatkan sensitivitas model terhadap pola serangan
168 yang tidak biasa sekaligus tetap mempertahankan kemampuan pemodelan hubungan jangka
169 panjang antar waktu.

170 Berdasarkan uraian di atas, masih terdapat ruang penelitian untuk mengembangkan
171 sistem deteksi intrusi yang tidak hanya akurat, tetapi juga mampu memanfaatkan pola
172 temporal secara eksplisit dan dapat diinterpretasikan. Penelitian ini bertujuan merancang
173 dan mengevaluasi kerangka kerja hibrid yang mengintegrasikan *Isolation Forest* (IF) sebagai
174 penghasil skor anomali dan *Temporal Fusion Transformer* (TFT) sebagai model pemodelan

temporal untuk sistem deteksi intrusi jaringan komputer. Keunikan pendekatan ini terletak pada pemanfaatan skor anomali IF sebagai fitur tambahan dalam urutan data masukan TFT, sehingga model tidak hanya mempelajari pola temporal jangka panjang dari lalu lintas jaringan komputer, tetapi juga mempertimbangkan informasi derajat ketidaknormalan pada setiap titik waktu secara eksplisit. Perlu ditekankan bahwa pendekatan ini tidak dimaksudkan untuk memprediksi waktu pasti terjadinya serangan, melainkan memodelkan kecenderungan status lalu lintas jaringan komputer pada horizon pendek berdasarkan pola historis yang telah diamati. Hasil dari penelitian ini diharapkan dapat berkontribusi dalam pengembangan sistem deteksi intrusi yang lebih adaptif, transparan, dan efektif dalam menghadapi ancaman siber yang terus berkembang.

Untuk mewujudkan tujuan tersebut, penelitian ini menggunakan dataset UNSW-NB15 sebagai sumber data utama. Dataset ini dirancang untuk mengatasi keterbatasan dataset IDS generasi lama seperti KDD99 dan NSL-KDD, terutama dalam merepresentasikan lalu lintas jaringan komputer modern dan variasi serangan kontemporer pada lingkungan terkontrol (Moustafa & Slay, 2015). Dataset ini memuat lebih dari 2,5 juta rekaman dengan 49 atribut, termasuk atribut lalu lintas jaringan komputer dan label kelas, serta mencakup sembilan kategori serangan yaitu *Fuzzers*, *Analysis*, *Backdoors*, *DoS*, *Exploits*, *Generic*, *Reconnaissance*, *Shellcode*, dan *Worms* di samping lalu lintas normal. Meskipun UNSW-NB15 sejak awal tidak dirancang khusus sebagai dataset deret waktu, ketersediaan atribut cap waktu pada setiap rekaman memungkinkan pengurutan data secara kronologis dan pembentukan urutan data menggunakan pendekatan *sliding window* sebagai adaptasi untuk pemodelan temporal. Namun demikian, dataset ini memiliki karakteristik ketidakseimbangan kelas (*class imbalance*) yang sangat signifikan. Lalu lintas normal mendominasi dengan sekitar 2,2 juta rekaman, sedangkan kategori serangan bervariasi antara 215.481 rekaman pada *Generic* hingga hanya 174 rekaman pada *Worms* (Moustafa & Slay, 2015). Kondisi ini berpotensi menyebabkan bias model terhadap kelas mayoritas, penurunan sensitivitas terhadap pola serangan minoritas, serta hasil evaluasi yang menyesatkan apabila hanya mengandalkan akurasi sebagai satu-satunya metrik (Chinnasamy et al., 2025). Oleh karena itu, penelitian ini membatasi cakupan klasifikasi pada empat kelas, yaitu Normal, Generic, Exploits, dan Fuzzers, untuk membatasi dampak ketidakseimbangan ekstrem akibat kelas dengan jumlah rekaman sangat kecil serta menjaga stabilitas proses pelatihan dan evaluasi model. Pemilihan kelas ini didasarkan pada pertimbangan bahwa masing-masing kelas yang digunakan memiliki jumlah rekaman yang relatif lebih memadai dibandingkan kelas minoritas ekstrem seperti Worms, Shellcode, Backdoors, dan Analysis, sehingga lebih layak untuk dijadikan dasar evaluasi model multikelas (Moustafa & Slay, 2015). Selain itu, evaluasi model tidak hanya bertumpu pada akurasi, tetapi juga menggunakan metrik *precision*, *recall*, dan *F1-score* yang lebih tepat dalam kondisi data tidak seimbang, serta *false alarm rate* untuk mengukur proporsi alarm palsu yang dihasilkan sistem.

2 Masalah Penelitian

Berdasarkan latar belakang yang telah diuraikan, penelitian ini merumuskan permasalahan sebagai berikut:

1. Bagaimana merancang dan mengimplementasikan pendekatan yang mengintegrasikan

217 skor anomali dari *Isolation Forest* dalam model *Temporal Fusion Transformer* untuk
218 sistem deteksi intrusi jaringan komputer?

219 2. Bagaimana performa model *Temporal Fusion Transformer* dengan mengintegrasikan
220 skor anomali dari *Isolation Forest* untuk sistem deteksi intrusi jaringan komputer?

221 3 Tujuan Penelitian

222 Sesuai dengan rumusan masalah di atas, tujuan dari penelitian ini adalah:

- 223 1. Merancang dan mengimplementasikan pendekatan yang mengintegrasikan skor anomali
224 dari *Isolation Forest* sebagai fitur tambahan dalam model *Temporal Fusion Trans-*
225 *former* untuk sistem deteksi intrusi jaringan komputer.
- 226 2. Mengukur dan menganalisis performa model *Temporal Fusion Transformer* dengan
227 mengintegrasikan skor anomali dari *Isolation Forest* untuk sistem deteksi intrusi jaringan
228 komputer.

229 4 Batasan Penelitian

230 Untuk menjaga fokus dan kedalaman kajian, penelitian ini dibatasi oleh hal-hal berikut:

- 231 1. Penelitian menggunakan dataset UNSW-NB15 yang terdiri dari sekitar 2,5 juta data
232 dan 49 atribut, serta label kelas.
- 233 2. Klasifikasi dibatasi pada empat kelas, yaitu *Normal*, *Generic*, *Exploits*, dan *Fuzzers*.
234 Pemilihan kelas dilakukan untuk membatasi dampak ketidakseimbangan ekstrem aki-
235 bat kelas dengan jumlah rekaman sangat kecil, sekaligus tetap mempertahankan be-
236 berapa pola serangan utama dalam UNSW-NB15.
- 237 3. Data lalu lintas jaringan komputer direpresentasikan sebagai deret waktu multivariat
238 menggunakan pendekatan *sliding window*, dengan panjang jendela historis W dan
239 jendela target T yang ditentukan melalui eksperimen dalam rentang terbatas.
- 240 4. Penanganan ketidakseimbangan kelas difokuskan pada *class weighting* karena tidak
241 mengubah struktur temporal data. Teknik oversampling atau undersampling hanya
242 digunakan sebagai eksperimen pembandingan apabila tidak mengganggu struktur tem-
243 poral data latih.
- 244 5. Evaluasi performa model dilakukan secara *offline* menggunakan metrik akurasi, *pre-*
245 *cision*, *recall*, F1-score, dan *false alarm rate*. Metrik *precision*, *recall*, dan F1-score
246 diprioritaskan karena lebih representatif pada data tidak seimbang.

247 5 Tinjauan Pustaka

248 5.1 Sistem Deteksi Intrusi (IDS)

249 *Intrusion Detection System* (IDS) merupakan sistem keamanan yang dirancang untuk
250 memantau aktivitas pada jaringan komputer atau host guna mendeteksi perilaku yang

mengindikasikan adanya serangan maupun aktivitas tidak sah (Alkasassbeh & Baddar, 2023). Konsep IDS modern berakar pada penelitian Anderson pada tahun 1980 yang membahas pentingnya *security audit trail*, pemantauan aktivitas sistem, dan mekanisme pengawasan terhadap perilaku pengguna dalam sistem komputer (James & Co, 1980). Anderson menjelaskan bahwa pencatatan aktivitas (*audit trail*) memainkan peran penting dalam mendeteksi akses tidak sah maupun perilaku pengguna yang berlebihan terhadap sumber daya sistem (James & Co, 1980). Konsep tersebut kemudian berkembang menjadi fondasi berbagai sistem IDS modern yang digunakan untuk mendeteksi ancaman keamanan secara otomatis.

IDS dapat diklasifikasikan dari dua sudut pandang utama, yaitu berdasarkan lokasi penerapan dan berdasarkan metode deteksi. Berdasarkan lokasi penerapannya, IDS mencakup Host-based Intrusion Detection System (HIDS), Network-based Intrusion Detection System (NIDS), Wireless Intrusion Detection System (WIDS), dan Network Behavior Analysis IDS (NBAIDS). HIDS memantau aktivitas pada perangkat atau host tertentu, seperti log sistem, aktivitas proses, dan perubahan file, sehingga mampu memberikan visibilitas yang detail terhadap aktivitas internal perangkat. Sebaliknya, NIDS memantau lalu lintas jaringan komputer pada tingkat paket maupun aliran data (*network flow*) sehingga lebih sesuai untuk mendeteksi serangan yang menyebar melalui jaringan komputer secara terpusat. WIDS difokuskan pada pemantauan jaringan komputer nirkabel, sedangkan NBAIDS menganalisis pola perilaku lalu lintas jaringan komputer untuk mengidentifikasi anomali yang menyimpang dari perilaku normal (Alkasassbeh & Baddar, 2023).

Berdasarkan metode deteksinya, IDS dapat dibedakan menjadi signature-based IDS, anomaly-based IDS, dan stateful protocol analysis IDS. Signature-based IDS mendeteksi serangan dengan mencocokkan pola lalu lintas terhadap basis data tanda tangan (*signature*) serangan yang telah diketahui sebelumnya. Pendekatan ini memiliki akurasi tinggi terhadap serangan yang telah dikenal dan umumnya menghasilkan *false positive* yang relatif rendah, tetapi memiliki keterbatasan dalam mendeteksi serangan baru atau *zero-day attack* yang belum memiliki signature (Alsoufi et al., 2021; Chinnasamy et al., 2025). Anomaly-based IDS mendeteksi penyimpangan terhadap pola perilaku normal sistem atau jaringan komputer, sehingga lebih adaptif terhadap pola serangan yang belum pernah diamati sebelumnya. Akan tetapi, pendekatan ini sering menghadapi tantangan berupa tingginya *false alarm rate* akibat sulitnya mendefinisikan batas yang jelas antara perilaku normal dan abnormal (Aleesa et al., 2020). Sementara itu, stateful protocol analysis IDS memeriksa status dan perilaku protokol komunikasi berdasarkan spesifikasi protokol yang valid.

Tantangan tambahan yang dihadapi oleh sistem IDS berbasis anomali adalah masalah ketidakseimbangan kelas (*class imbalance*) pada data lalu lintas jaringan komputer. Dalam kondisi operasional nyata, lalu lintas normal mendominasi secara masif dibandingkan lalu lintas serangan, sehingga distribusi kelas pada dataset IDS umumnya sangat tidak seimbang (Chinnasamy et al., 2025). Kondisi ini menimbulkan kecenderungan model untuk memprioritaskan kelas mayoritas selama pelatihan, akibatnya sensitivitas model terhadap kategori serangan yang jarang muncul (*minority class*) menurun secara signifikan (Chinnasamy et al., 2025). Implikasinya, model IDS da-

295 pat memperoleh nilai akurasi keseluruhan yang tinggi, namun justru gagal mendeteksi
 296 serangan minoritas yang secara operasional paling berbahaya. Oleh karena itu, eva-
 297 luasi sistem IDS berbasis anomali tidak cukup hanya mengandalkan akurasi, melainkan
 298 perlu melibatkan metrik yang lebih sensitif terhadap kinerja pada kelas minoritas, se-
 299 seperti *precision*, *recall*, *F1-score*, dan *false alarm rate* (Chinnasamy et al., 2025).
 300 Perbandingan seluruh kategori IDS berdasarkan lokasi penerapan (*deployment*) dan
 301 metode deteksi ditunjukkan pada Tabel 1. Penelitian ini berfokus pada pendekatan
 302 *Network-based Anomaly IDS* karena karakteristik dataset UNSW-NB15 merepresen-
 303 tasikan lalu lintas jaringan komputer modern dengan berbagai kategori serangan dan
 304 pola temporal yang kompleks. Pendekatan NIDS dipilih karena mampu melakukan pe-
 305 mantauan lalu lintas jaringan komputer secara menyeluruh dan lebih sesuai untuk ana-
 306 lisis data deret waktu berbasis aliran jaringan komputer. Selain itu, metode *anomaly-*
 307 *based* dipilih karena secara konseptual memiliki kemampuan mendeteksi pola seran-
 308 gan baru yang belum pernah diamati sebelumnya, yang menjadi kelemahan utama
 309 metode *signature-based* (Alsoufi et al., 2021; Chinnasamy et al., 2025). Dengan me-
 310 manfaatkan pendekatan anomaly-based, model diharapkan mampu mengenali pola lalu
 311 lintas abnormal berdasarkan perubahan perilaku temporal jaringan komputer secara
 312 lebih adaptif terhadap ancaman modern.

Tabel 1: Perbandingan kategori IDS berdasarkan deployment dan metode deteksi

Kategori	Deskripsi	Keunggulan	Keterbatasan
HIDS	Memantau aktivi- tas pada host atau perangkat tertentu	Detail terhadap aktivitas inter- nal sistem dan log perangkat	Tidak mampu memantau keselu- ruhan lalu lintas jaringan kom- puter
NIDS	Memantau lalu lintas jaringan komputer se- cara terpusat	Efektif mendeteksi serangan jaringan komputer secara real- time	Sulit menganalisis trafik terenkripsi
WIDS	Memantau jaringan komputer nirkabel	Efektif mendeteksi ancaman pada jaringan komputer <i>wireless</i>	Terbatas pada lingkungan komu- nikasi nirkabel
NBAIDS	Menganalisis perilaku lalu lintas jaringan komputer	Mampu mendeteksi pola anomali jaringan komputer	Membutuhkan analisis perilaku yang kompleks
Signature-based IDS	Deteksi berdasarkan pola serangan yang telah diketahui	Akurasi tinggi pada serangan yang dikenal	Tidak mampu mendeteksi zero- day attack
Anomaly-based IDS	Deteksi berdasarkan penyimpangan perilaku normal	Berpotensi mendeteksi pola serangan baru	Rentan menghasilkan false posi- tive tinggi
Stateful Protocol IDS	Analisis berdasarkan spesifikasi protokol ko- munikasi	Analisis protokol lebih men- dalam	Membutuhkan sumber daya komputasi tinggi

313 5.2 Data Deret Waktu (Time Series)

314 Data deret waktu (*time series*) merupakan sekumpulan observasi yang dicatat se-
 315 cara berurutan berdasarkan waktu sehingga urutan temporal antar observasi memiliki
 316 makna penting dalam analisis (Hamilton, 1994). Berbeda dengan data tabular biasa
 317 yang menganggap setiap observasi independen, data deret waktu memiliki ketergan-
 318 tungan temporal antar waktu sehingga nilai pada waktu sebelumnya dapat memen-
 319 garuhi nilai berikutnya (Faouzi, 2024). Karakteristik utamanya meliputi autokorelasi
 320 (*autocorrelation*), yaitu hubungan statistik antara nilai pada waktu saat ini dengan
 321 nilai pada beberapa waktu sebelumnya (*lag*), serta stasioneritas (*stationarity*), yaitu
 322 kondisi ketika distribusi statistik data seperti rata-rata dan varians relatif konstan ter-
 323 hadap waktu (Hamilton, 1994). Secara klasik, data deret waktu terdiri atas komponen
 324 tren (*trend*), musiman (*seasonality*), siklus (*cyclic*), dan residual atau *noise* (Hamil-

ton, 1994). Dalam konteks lalu lintas jaringan komputer, pola-pola tersebut dapat muncul sebagai perubahan volume paket, aktivitas pengguna, maupun lonjakan lalu lintas akibat serangan siber.

Representasi data deret waktu pada model pembelajaran mesin umumnya dilakukan menggunakan pendekatan *sliding window*, yaitu teknik yang membentuk sampel input dari sejumlah observasi historis untuk memodelkan target pada horizon waktu berikutnya (Lim & Zohren, 2021). Secara formal:

$$\{(X_{t-W+1}, \dots, X_t)\} \rightarrow Y_{(t+1, \dots, t+T)} \quad (1)$$

Pada Persamaan 1, setiap simbol memiliki makna sebagai berikut. W menyatakan panjang jendela historis, yaitu jumlah titik waktu lampau yang digunakan sebagai input model. t menyatakan indeks waktu saat ini, sehingga $X_{t-W+1}, \dots, X_t$ merupakan urutan observasi dari W titik waktu yang berurutan hingga waktu t . $X_t \in \mathbb{R}^F$ menyatakan vektor fitur pada titik waktu ke- t , dengan F menyatakan jumlah fitur yang digunakan. T menyatakan panjang jendela target (*forecast horizon*), yaitu jumlah titik waktu ke depan yang ingin dimodelkan. $Y_{(t+1, \dots, t+T)}$ menyatakan label atau nilai target pada horizon waktu berikutnya, yang dalam konteks penelitian ini berupa label kelas pada setiap titik waktu dalam jendela T . Dengan menggeser jendela satu langkah pada setiap iterasi, pendekatan ini menghasilkan serangkaian pasangan input-output yang mempertahankan urutan temporal data secara eksplisit.

Dalam perkembangan modern, pemodelan deret waktu tidak hanya terbatas pada satu langkah waktu, tetapi juga dapat diperluas untuk memodelkan beberapa langkah waktu sekaligus dalam bentuk *multi-horizon forecasting* (Lim & Zohren, 2021). Tantangan utama pendekatan ini adalah meningkatnya ketidakpastian pada horizon waktu yang lebih jauh, sehingga model perlu menangkap dependensi temporal jangka panjang secara efektif. Data jaringan komputer modern pada dasarnya merupakan aliran observasi temporal yang terus berubah terhadap waktu (Psychogyios et al., 2024), sehingga transformasi data lalu lintas jaringan komputer ke representasi deret waktu memungkinkan model mendeteksi pola anomali temporal seperti lonjakan trafik mendadak dan pola komunikasi abnormal yang mengindikasikan serangan siber (Psychogyios et al., 2024; Joshi & Gurusamy, 2025).

5.3 Isolation Forest

Isolation Forest (IF) merupakan metode *unsupervised anomaly detection* yang diperkenalkan oleh Liu et al. untuk mendeteksi anomali berdasarkan konsep isolasi (*isolation*) daripada pemodelan distribusi data normal (Liu et al., 2008, 2012). Berbeda dengan metode berbasis jarak (*distance-based*) maupun kepadatan (*density-based*), *Isolation Forest* memanfaatkan karakteristik utama anomali yang bersifat "few and different", yaitu jumlahnya relatif sedikit dan memiliki atribut yang berbeda dari mayoritas data normal, sehingga cenderung lebih mudah dipisahkan melalui proses partisi acak (Liu et al., 2008, 2012). Dalam konteks sistem deteksi intrusi jaringan komputer, karakteristik ini relevan karena lalu lintas serangan umumnya menghasilkan pola statistik yang menyimpang dari perilaku jaringan komputer yang normal (Zahoor et al., 2025).

365 Mekanisme *Isolation Forest* dibangun menggunakan struktur pohon biner yang dise-
 366 but *Isolation Tree* (*iTree*), yang dibentuk melalui proses partisi rekursif secara acak
 367 (Liu et al., 2012). Pada setiap *node*, sebuah fitur dan nilai batas pemisah (*split point*)
 368 dipilih secara acak, lalu data dibagi ke dalam dua cabang berdasarkan apakah nilai
 369 fitur tersebut berada di bawah atau di atas nilai batas tersebut. Proses partisi ini diu-
 370 lang secara rekursif hingga setiap data terisolasi atau kedalaman maksimum tercapai.
 371 Data anomali cenderung lebih cepat terisolasi sehingga memiliki panjang lintasan (*path*
 372 *length*) yang lebih pendek dibanding data normal (Liu et al., 2008). Secara formal,
 373 panjang lintasan data x pada sebuah *iTree* dinyatakan sebagai $h(x)$, dan skor anomali
 374 dihitung berdasarkan ekspektasi $E[h(x)]$ terhadap seluruh pohon dalam *forest*:

$$s(x, n) = 2^{-\frac{E[h(x)]}{c(n)}} \quad (2)$$

375 Pada Persamaan 2, $s(x, n) \in (0, 1)$ adalah skor anomali data x , $E[h(x)]$ adalah ek-
 376 spektasi panjang lintasan terhadap seluruh pohon, dan $c(n)$ adalah faktor normalisasi
 377 berupa ekspektasi panjang lintasan pada *Binary Search Tree* acak berukuran n (Liu
 378 et al., 2012).

379 Nilai $c(n)$ didefinisikan sebagai:

$$c(n) = 2H(n-1) - \frac{2(n-1)}{n}, \quad H(i) = \ln(i) + 0.5772 \quad (3)$$

380 di mana $H(i)$ merupakan aproksimasi *harmonic number* ke- i , yaitu jumlah deret ke-
 381 balikan bilangan bulat hingga indeks i . Dalam implementasi *Isolation Forest*, nilai
 382 tersebut didekati menggunakan $H(i) \approx \ln(i) + 0,5772$, dengan 0,5772 merupakan kon-
 383 stanta Euler-Mascheroni (Liu et al., 2012). Nilai skor mendekati 1 mengindikasikan
 384 anomali karena panjang lintasan data tersebut jauh lebih pendek dari rata-rata, nilai
 385 mendekati 0 mengindikasikan data normal dengan lintasan yang panjang, sedangkan
 386 nilai di sekitar 0,5 menunjukkan status yang tidak dapat dibedakan secara jelas an-
 387 tara normal dan anomali (Liu et al., 2012). Kompleksitas pelatihan IF berada pada
 388 orde $O(n \log n)$ dengan perhitungan skor anomali $O(\log n)$, lebih efisien dibandingkan
 389 metode berbasis jarak maupun kepadatan yang memerlukan perhitungan pasangan
 390 jarak secara eksplisit (Liu et al., 2008). Perbandingan IF dengan metode lain ditun-
 391 jukkan pada Tabel 2.

Tabel 2: Perbandingan beberapa metode *anomaly detection*

Metode	Prinsip	Kompleksitas	Kelebihan	Keterbatasan
<i>Isolation Forest</i>	Isolasi acak meng- gunakan <i>iTree</i>	$O(n \log n)$	Cepat, scalable, tidak berbasis jarak atau densitas	Sensitif terhadap pola partisi tertentu
One-Class SVM	Pembentukan <i>boundary</i> data normal	Tinggi pada dataset besar	Mampu membentuk <i>boundary</i> kompleks	Sensitif terhadap ker- nel dan parameter
Local Outlier Fac- tor (LOF)	Perbandingan kepadatan lokal antar tetangga	Tinggi akibat perhitungan jarak	Baik untuk <i>local</i> <i>anomaly</i>	Performa menurun pada dimensi tinggi

392 Dalam penelitian ini, *Isolation Forest* tidak digunakan sebagai model klasifikasi utama,

393 melainkan sebagai penghasil skor anomali (*anomaly scorer*) untuk memperkaya repre-
 394 sentasi fitur pada model *Temporal Fusion Transformer* (TFT). Skor anomali setiap
 395 titik data diintegrasikan sebagai fitur tambahan ke- $(F + 1)$ pada sekuens input, se-
 396 hingga model tidak hanya mempelajari pola temporal dari fitur jaringan komputer
 397 mentah, tetapi juga mempertimbangkan tingkat ketidaknormalan statistik setiap titik
 398 waktu secara eksplisit. Pelatihan IF pada subset Normal dipilih agar skor anomali
 399 merepresentasikan derajat penyimpangan terhadap pola lalu lintas normal. Dengan
 400 demikian, skor ini terutama berfungsi sebagai indikator abnormalitas Normal-vs-non-
 401 Normal, sedangkan kemampuan model dalam membedakan antar kelas serangan tetap
 402 dipelajari oleh TFT melalui kombinasi fitur jaringan komputer, pola temporal, dan
 403 skor anomali tersebut.

404 5.4 Transformer dan *Temporal Fusion Transformer*

405 5.4.1 Arsitektur Transformer

406 Transformer merupakan arsitektur *deep learning* yang diperkenalkan oleh Vaswani
 407 et al. untuk pemrosesan data sekuens tanpa menggunakan mekanisme rekursif se-
 408 perti pada model sekuens tradisional, misalnya Recurrent Neural Network (RNN)
 409 dan Long Short-Term Memory (LSTM) (Vaswani et al., 2017). Berbeda dengan
 410 RNN dan LSTM yang memproses elemen sekuens secara berurutan, Transformer
 411 memanfaatkan mekanisme *self-attention* untuk mempelajari hubungan antar ele-
 412 men dalam sekuens secara paralel sehingga memungkinkan proses pelatihan yang
 413 lebih efisien dan kemampuan menangkap dependensi jangka panjang yang lebih
 414 baik (Wen et al., 2023). Kemampuan tersebut menjadikan Transformer sangat
 415 efektif pada berbagai tugas pemodelan sekuens, termasuk pemrosesan bahasa
 416 alami, pengenalan suara, serta *time series forecasting* (Su et al., 2025).

417 Secara umum, arsitektur Transformer terdiri atas *encoder* dan *decoder*, di mana
 418 setiap bloknya memuat mekanisme *multi-head self-attention* dan *feed-forward*
 419 *neural network* (Vaswani et al., 2017). Mekanisme *multi-head self-attention* memu-
 420 ngkinkan model mempelajari hubungan antar elemen dalam sekuens melalui be-
 421 berapa representasi perhatian secara paralel, sedangkan *feed-forward neural net-*
 422 *work* berfungsi mengolah hasil perhatian tersebut menjadi representasi fitur yang
 423 lebih kompleks. Karena Transformer tidak menggunakan mekanisme rekursif se-
 424 perti RNN atau LSTM, informasi urutan waktu dimasukkan melalui *positional*
 425 *encoding*, yaitu representasi posisi yang ditambahkan pada *embedding* input agar
 426 model tetap dapat mengenali urutan elemen dalam sekuens (Wen et al., 2023).
 427 Komponen inti Transformer adalah mekanisme *self-attention*, yaitu mekanisme
 428 yang menghitung tingkat keterkaitan antar elemen dalam sekuens, sebagaimana
 429 ditunjukkan pada Persamaan 4.

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (4)$$

430 Pada Persamaan 4, Q , K , dan V masing-masing merepresentasikan *query*, *key*,
 431 dan *value* yang diperoleh dari proyeksi input sekuens. Notasi K^T menyatakan
 432 transpose dari matriks K , sedangkan d_k menyatakan dimensi vektor *key* yang
 433 digunakan sebagai faktor normalisasi melalui $\sqrt{d_k}$ untuk menjaga stabilitas nilai

attention dan gradien (Vaswani et al., 2017). Transformer kemudian memperluas mekanisme ini menjadi *multi-head attention*, yaitu beberapa proses *attention* yang dijalankan secara paralel agar model dapat menangkap dependensi temporal pada berbagai skala waktu sekaligus (Wen et al., 2023).

5.4.2 Temporal Fusion Transformer (TFT)


Temporal Fusion Transformer (TFT) merupakan pengembangan arsitektur Transformer yang dirancang khusus untuk tugas *multi-horizon time series forecasting* dengan fokus pada pemodelan deret waktu dan interpretabilitas model (Lim et al., 2021). Berbeda dengan Transformer standar, TFT dirancang untuk menangani berbagai jenis input heterogen secara simultan, termasuk fitur statik (*static covariates*), observasi historis, serta variabel masa depan yang telah diketahui sebelumnya (*known future inputs*) (Lim et al., 2021). Fitur statik merupakan fitur yang nilainya tetap sepanjang suatu sekuens waktu, sedangkan observasi historis merupakan data yang berubah dari waktu ke waktu dan digunakan untuk mempelajari pola temporal. Arsitektur ini menggabungkan kemampuan *recurrent layer*, seperti LSTM, untuk mempelajari dependensi lokal jangka pendek dengan mekanisme *attention* untuk menangkap dependensi jangka panjang.

Arsitektur umum TFT ditunjukkan pada Gambar 1. Model ini terdiri atas beberapa komponen utama seperti *Variable Selection Network* (VSN), *Gated Residual Network* (GRN), *LSTM encoder-decoder*, serta *interpretable multi-head attention*. VSN berfungsi melakukan seleksi dan pembobotan fitur secara adaptif sehingga model dapat menekankan fitur yang lebih relevan pada setiap titik waktu. GRN digunakan untuk mengontrol aliran informasi dalam jaringan komputer dengan mempertahankan informasi penting dan menekan informasi yang kurang relevan. Sementara itu, *LSTM encoder-decoder* membantu menangkap dependensi temporal lokal atau jangka pendek, sedangkan *interpretable multi-head attention* digunakan untuk mempelajari hubungan temporal jangka panjang secara lebih transparan. Kombinasi komponen tersebut memungkinkan TFT melakukan seleksi fitur adaptif sekaligus mempertahankan interpretabilitas model (Lim et al., 2021).

Salah satu komponen penting dalam TFT adalah *Gated Residual Network* (GRN), yaitu modul yang digunakan untuk mengontrol aliran informasi dan menekan komponen yang kurang relevan (Lim et al., 2021). GRN memanfaatkan kombinasi *Exponential Linear Unit* (ELU), *Gated Linear Unit* (GLU), *residual connection*, serta *layer normalization*. ELU berperan sebagai fungsi aktivasi non-linear, GLU berperan sebagai mekanisme gerbang untuk mengatur informasi yang diteruskan, *residual connection* membantu mempertahankan informasi dari input awal, sedangkan *layer normalization* digunakan untuk menjaga stabilitas pelatihan. Secara matematis, bentuk ringkas GRN dapat dituliskan sebagai Persamaan 5.

$$\text{GRN}(a, c) = \text{LayerNorm}(a + \text{GLU}(\eta_1)) \quad (5)$$

Pada Persamaan 5, a adalah input utama, c adalah konteks tambahan opsional, dan η_1 adalah hasil transformasi non-linear yang melibatkan a serta, apabila tersedia, konteks tambahan c . Komponen GLU (*Gated Linear Unit*) mengontrol



Gambar 1: Arsitektur *Temporal Fusion Transformer* (Lim et al., 2021)

aliran informasi melalui mekanisme gerbang berbasis sigmoid, sedangkan *residual connection* yang dinormalisasi dengan *LayerNorm* digunakan untuk menjaga stabilitas pelatihan (Lim et al., 2021). Selain GRN, TFT menggunakan *Variable Selection Network* (VSN) untuk pembobotan fitur secara adaptif pada setiap *timestep*.

Komponen lain yang menjadi keunggulan utama TFT adalah *interpretable multi-head attention*, yang dirancang agar lebih mudah diinterpretasikan dan difokuskan pada dependensi temporal jangka panjang yang paling signifikan (Lim et al., 2021). Kemampuan interpretabilitas ini penting dalam domain kritis seperti sistem deteksi intrusi jaringan komputer karena memungkinkan analisis pola temporal serangan secara lebih transparan. Meskipun TFT pada awalnya dikembangkan untuk tugas *multi-horizon forecasting*, arsitektur ini juga relevan untuk pemodelan deret waktu multivariat karena kemampuannya dalam menangkap hubungan temporal, melakukan seleksi fitur adaptif, dan menyediakan dasar interpretasi melalui mekanisme perhatian. TFT juga telah diterapkan pada deteksi anomali deret waktu multivariat dengan hasil yang menjanjikan (Ayhan et al., 2024).

Dalam penelitian ini, TFT digunakan sebagai model utama untuk mempelajari pola temporal lalu lintas jaringan komputer berdasarkan data multivariat hasil preprocessing dan pembentukan *sliding window*. Model ini tidak dimaksudkan untuk memprediksi waktu pasti terjadinya serangan, melainkan untuk mengklasifikasikan kecenderungan status lalu lintas pada horizon pendek berdasarkan pola historis yang telah diamati. Integrasi skor anomali dari Isolation Forest sebagai fitur tambahan memungkinkan model tidak hanya mempelajari dependensi temporal antar fitur jaringan komputer, tetapi juga mempertimbangkan tingkat abnormalitas statistik setiap titik waktu secara eksplisit. Dengan kombinasi kemampuan *attention*, seleksi fitur adaptif, dan interpretabilitas bawaan,

TFT diharapkan mampu meningkatkan performa sistem deteksi intrusi sekaligus memberikan pemahaman yang lebih baik terhadap pola serangan jaringan komputer. Meskipun TFT pada awalnya dikembangkan untuk tugas *multi-horizon forecasting*, penelitian ini mengadaptasi arsitektur tersebut untuk klasifikasi temporal multikelas dengan target berupa label status lalu lintas jaringan komputer pada horizon atau jendela tertentu. Adaptasi dilakukan dengan mengganti keluaran akhir model menjadi *classification head* berbasis *softmax*, sehingga untuk setiap horizon target model menghasilkan probabilitas keanggotaan terhadap empat kelas, yaitu *Normal*, *Generic*, *Exploits*, dan *Fuzzers*. Dengan demikian, fungsi objektif yang digunakan bukan *quantile loss* sebagaimana pada forecasting kontinu, melainkan *cross-entropy loss* yang sesuai untuk klasifikasi multikelas. Fitur masukan difokuskan pada observasi historis lalu lintas jaringan komputer dan skor anomali, sedangkan variabel masa depan yang telah diketahui sebelumnya (*known future inputs*) tidak menjadi komponen utama karena tidak tersedia secara alami dalam konteks deteksi intrusi jaringan komputer.

5.5 Dataset UNSW-NB15

Dataset UNSW-NB15 merupakan dataset lalu lintas jaringan komputer yang banyak digunakan untuk penelitian dan evaluasi *Network Intrusion Detection System* (NIDS). Dataset ini dikembangkan oleh Australian Centre for Cyber Security (ACCS), University of New South Wales, untuk menyediakan representasi lalu lintas jaringan komputer modern yang lebih realistis dibandingkan dataset IDS generasi sebelumnya seperti KDD99 dan NSL-KDD (Moustafa & Slay, 2015). Dataset ini dibangun menggunakan perangkat IXIA PerfectStorm pada lingkungan *Cyber Range Lab* ACCS dengan tujuan menghasilkan kombinasi lalu lintas normal modern dan lalu lintas serangan sintesis kontemporer (Moustafa & Slay, 2015). Selama proses pembangkitan data, perangkat IXIA dikonfigurasi menggunakan basis data kerentanan yang diperbarui secara berkala dari CVE (*Common Vulnerabilities and Exposures*), sehingga pola serangan yang dihasilkan merepresentasikan ancaman jaringan komputer modern (Moustafa & Slay, 2015). Proses pengambilan lalu lintas jaringan komputer dilakukan menggunakan *tcp-dump*, sementara ekstraksi fitur dilakukan menggunakan Argus, Bro-IDS, dan sejumlah algoritma tambahan yang dikembangkan secara khusus (Moustafa & Slay, 2016).

Dataset UNSW-NB15 terdiri dari 49 atribut, yang mencakup atribut lalu lintas jaringan komputer dan label kelas. Atribut-atribut tersebut secara umum dapat dikelompokkan menjadi fitur dasar (*basic features*), fitur konten (*content features*), fitur berbasis waktu (*time features*), fitur aliran (*flow features*), dan fitur tambahan hasil ekstraksi (*generated features*) (Moustafa & Slay, 2016). Fitur-fitur tersebut mencakup informasi protokol, jumlah paket, durasi koneksi, ukuran *payload*, statistik koneksi, hingga karakteristik perilaku lalu lintas jaringan komputer yang lebih kompleks. Keberadaan atribut waktu pada dataset ini menjadi penting dalam penelitian karena memungkinkan pengurutan rekaman secara kronologis dan pembentukan representasi deret waktu melalui pendekatan *sliding window*. Meskipun UNSW-NB15 tidak dirancang secara khusus sebagai dataset deret waktu, atribut waktu tersebut memungkinkan pola perubahan perilaku jaringan komputer diamati secara temporal. Dalam dokumen fitur UNSW-NB15, terdapat 49 atribut yang mencakup atribut lalu lintas jaringan kom-

puter serta dua atribut target, yaitu **attack_cat** dan **Label**. Pada penelitian ini, **attack_cat** digunakan sebagai target klasifikasi multikelas, sedangkan **Label** tidak digunakan sebagai fitur input karena merepresentasikan label biner Normal-vs-Attack. Dengan demikian, fitur input model dibentuk dari atribut non-target setelah tahap praproses. Atribut waktu seperti **Stime** dan **Ltime** digunakan terutama untuk pengurutan kronologis data. Karena **Stime** dan **Ltime** hanya digunakan untuk pengurutan data, maka jumlah fitur input dasar yang digunakan model adalah 45 fitur, sedangkan model TFT-IF menggunakan 46 fitur setelah penambahan skor anomali *Isolation Forest*.

Selain lalu lintas normal, UNSW-NB15 mencakup sembilan kategori serangan modern, yaitu *Fuzzers*, *Analysis*, *Backdoors*, *DoS*, *Exploits*, *Generic*, *Reconnaissance*, *Shellcode*, dan *Worms* (Moustafa & Slay, 2015). Distribusi jumlah rekaman pada seluruh kelas ditunjukkan pada Tabel 3. Tampak bahwa distribusi dataset ini sangat tidak seimbang (*severely imbalanced*): lalu lintas normal mendominasi dengan 2.218.761 rekaman (87,35%), diikuti kategori *Generic* sebagai kelas serangan terbesar dengan 215.481 rekaman (8,48%), sedangkan kategori *Worms* hanya terdiri atas 174 rekaman (0,01%).

Tabel 3: Distribusi kelas pada dataset UNSW-NB15. Tanda (★) menandai kelas yang digunakan dalam penelitian ini.

Kategori	Jumlah Rekaman	Persentase
Normal (★)	2.218.761	87,35%
Generic (★)	215.481	8,48%
Exploits (★)	44.525	1,75%
Fuzzers (★)	24.246	0,95%
DoS	16.353	0,64%
Reconnaissance	13.987	0,55%
Analysis	2.677	0,11%
Backdoors	2.329	0,09%
Shellcode	1.133	0,04%
Worms	174	0,01%

Ketidakseimbangan kelas (*class imbalance*) yang ekstrem ini menimbulkan beberapa tantangan metodologis yang perlu ditangani secara eksplisit. Pertama, model berpotensi mengalami bias terhadap kelas mayoritas karena meminimalkan fungsi *loss* secara keseluruhan lebih mudah dicapai dengan memprediksi kelas dominan tanpa benar-benar mempelajari pola kelas minoritas. Kedua, sensitivitas model terhadap kategori serangan yang jarang muncul, seperti *Shellcode* dan *Worms*, cenderung sangat rendah sehingga serangan berbahaya justru lebih mungkin lolos dari deteksi. Ketiga, metrik akurasi menjadi tidak representatif pada kondisi data tidak seimbang karena model yang selalu memprediksi kelas mayoritas pun dapat menghasilkan akurasi tinggi meski tidak memiliki kemampuan deteksi yang sesungguhnya (Chinnasamy et al., 2025).

Untuk menangani persoalan ini, penelitian membatasi eksperimen pada empat kelas yang dipilih berdasarkan representativitas distribusinya, yaitu *Normal*, *Generic*, *Exploits*, dan *Fuzzers*. Keempat kelas ini dipilih karena memiliki jumlah rekaman yang relatif lebih memadai dibandingkan kelas minoritas ekstrem seperti *Worms*, *Shellcode*, *Backdoors*, dan *Analysis*, sehingga lebih layak digunakan sebagai dasar evaluasi model multikelas. Pengurangan jumlah kelas tidak menghilangkan masalah ketidakseimbangan

gan data sepenuhnya, tetapi bertujuan membatasi ketidakseimbangan ekstrem akibat kelas dengan jumlah rekaman sangat kecil seperti Worms, Shellcode, Backdoors, dan Analysis. Dengan memilih Normal, Generic, Exploits, dan Fuzzers, penelitian tetap mempertahankan beberapa pola serangan utama dengan jumlah rekaman yang lebih layak untuk evaluasi model multikelas. Pengurangan cakupan dari sepuluh kelas keseluruhan, yaitu satu kelas normal dan sembilan kategori serangan, menjadi empat kelas bertujuan menjaga stabilitas proses pelatihan dan mempertahankan representativitas evaluasi model. Meskipun demikian, seluruh distribusi kelas tetap dipertahankan pada Tabel 3 sebagai konteks karakteristik dataset secara menyeluruh.

5.6 Penanganan Ketidakseimbangan Data

Ketidakseimbangan data (*class imbalance*) terjadi ketika jumlah sampel pada suatu kelas jauh lebih besar dibandingkan kelas lainnya, sehingga model cenderung bias terhadap kelas mayoritas dan kurang sensitif terhadap kelas minoritas (Altalhan et al., 2025). Tingkat ketidakseimbangan dapat diukur menggunakan *imbalance ratio* (IR), yaitu rasio antara jumlah sampel pada kelas terbesar dan jumlah sampel pada kelas terkecil:

$$IR = \frac{\max(n_k)}{\min(n_k)} \quad (6)$$

Pada Persamaan 6, n_k menyatakan jumlah sampel pada kelas ke- k , $\max(n_k)$ menyatakan jumlah sampel pada kelas mayoritas, dan $\min(n_k)$ menyatakan jumlah sampel pada kelas minoritas. Pada dataset UNSW-NB15, nilai IR antara kelas *Normal* sebagai kelas terbesar dan *Worms* sebagai kelas terkecil mencapai sekitar 12.751, yang menunjukkan ketidakseimbangan yang sangat ekstrem (Zoghi & Serpen, 2021). Selain itu, UNSW-NB15 juga dilaporkan memiliki masalah *class overlap*, yaitu kondisi ketika sampel dari beberapa kelas berada pada wilayah fitur yang saling tumpang tindih sehingga batas keputusan antar kelas lebih sulit dipelajari (Zoghi & Serpen, 2021).

Penanganan ketidakseimbangan data dapat dilakukan melalui tiga pendekatan utama. *Oversampling* menambah jumlah sampel kelas minoritas. Salah satu metode yang umum digunakan adalah *Synthetic Minority Oversampling Technique* (SMOTE), yaitu teknik yang membentuk sampel sintetis melalui interpolasi antar sampel kelas minoritas (Altalhan et al., 2025; Carvalho et al., 2025). Namun, SMOTE perlu diterapkan secara hati-hati pada data temporal karena berpotensi merusak struktur urutan waktu apabila diterapkan setelah pembentukan *sliding window*. Oleh karena itu, strategi utama yang diprioritaskan dalam penelitian ini adalah *class weighting* karena tidak mengubah struktur temporal data. Oversampling atau undersampling dapat dieksplorasi hanya pada data latih dengan mempertimbangkan apakah penerapannya tetap menjaga struktur sekuensial hasil *sliding window*. Sebaliknya, *undersampling* mengurangi jumlah sampel kelas mayoritas agar distribusi data menjadi lebih seimbang. Sementara itu, *class weighting* memberikan bobot kesalahan yang lebih besar pada kelas minoritas selama pelatihan tanpa mengubah jumlah sampel, sehingga model didorong untuk lebih memperhatikan pola kelas minoritas (BAKIRARAR & ELHAN, 2023). Dalam penelitian ini, strategi penanganan ketidakseimbangan data akan dieksplorasi melalui satu atau lebih pendekatan tersebut, kemudian dampaknya dievaluasi

menggunakan metrik *precision*, *recall*, dan F1-score yang lebih representatif pada data tidak seimbang dibandingkan akurasi tunggal (Altalhan et al., 2025; BAKIRARAR & ELHAN, 2023).

5.7 Jenis Serangan dalam UNSW-NB15

Dataset UNSW-NB15 mencakup sembilan kategori serangan yang dihasilkan menggunakan perangkat IXIA PerfectStorm dalam lingkungan simulasi terkontrol di Australian Centre for Cyber Security (ACCS), University of New South Wales (Moustafa & Slay, 2015). Setiap kategori merepresentasikan ancaman jaringan komputer modern dengan mekanisme dan karakteristik lalu lintas yang berbeda-beda, sehingga dataset ini lebih representatif dibandingkan dataset IDS generasi lama seperti KDD99 dan NSL-KDD (Moustafa & Slay, 2015). Sebagaimana telah dijelaskan pada subbab sebelumnya, penelitian ini membatasi eksperimen pada empat kelas, yaitu *Normal*, *Generic*, *Exploits*, dan *Fuzzers*, berdasarkan pertimbangan representativitas distribusi dan stabilitas pelatihan model. Berikut diuraikan karakteristik tiga kategori serangan yang digunakan dalam penelitian, sedangkan kelas *Normal* digunakan sebagai representasi lalu lintas non-serangan.

5.7.1 *Fuzzers*

Serangan *Fuzzers* bekerja dengan mengirimkan masukan acak, tidak valid, atau termutasi ke sistem target untuk memicu kerentanan seperti *buffer overflow* dan *integer overflow* (McNally et al., 2012; Cai et al., 2015). Aktivitas ini menghasilkan pola lalu lintas yang repetitif, fluktuatif, dan mengandung *payload* tidak lazim dibandingkan lalu lintas normal. Dalam dataset UNSW-NB15, kategori ini terdiri dari 24.246 rekaman (0,95% dari total dataset) (Moustafa & Slay, 2015). Karakteristik trafikanya yang tidak stabil dan berulang menjadikan kategori *Fuzzers* relevan untuk dianalisis menggunakan pendekatan deret waktu dan skor anomali, karena penyimpangan statistiknya terhadap lalu lintas normal dapat diamati secara temporal.

5.7.2 *Exploits*

Serangan *Exploits* memanfaatkan kelemahan keamanan perangkat lunak atau sistem operasi untuk memperoleh akses tidak sah maupun menjalankan kode berbahaya (Moustafa & Slay, 2015). Tingkat kemudahan eksploitasi suatu kerentanan umumnya diukur menggunakan *Common Vulnerability Scoring System* (CVSS) (Kijisanayothin & Hewett, 2013). Aktivitas eksploitasi biasanya melibatkan percobaan koneksi, pengiriman *payload* abnormal, dan respons sistem terhadap serangan (Monte, 2015). Dalam dataset UNSW-NB15, kategori *Exploits* terdiri dari 44.525 rekaman (1,75% dari total dataset) dan menjadi kelas serangan terbesar kedua setelah *Generic* (Moustafa & Slay, 2015). Hubungan temporal antar tahapan eksploitasi, mulai dari percobaan koneksi hingga keberhasilan penetrasi, menjadikan pendekatan berbasis deret waktu dan skor anomali relevan untuk mengenali pola serangan ini.

5.7.3 *Generic*

Serangan *Generic* merupakan serangan berbasis *brute-force* terhadap mekanisme kriptografi tanpa bergantung pada kelemahan spesifik algoritma tertentu (Mous-

663 tafa & Slay, 2015). Aktivitas ini dilakukan dengan mencoba berbagai kemung-
664 kinan kunci atau kombinasi secara sistematis hingga diperoleh nilai yang valid
665 (Alsariera, 2022). Karena proses tersebut berlangsung berulang dalam jumlah
666 besar, lalu lintas yang dihasilkan bersifat intens dan persisten. Dalam dataset
667 UNSW-NB15, kategori *Generic* memiliki jumlah rekaman terbesar di antara selu-
668 ruh kategori serangan, yaitu 215.481 rekaman atau 8,48% dari total dataset
669 (Moustafa & Slay, 2015). Dominasi kategori ini menjadikannya faktor penting
670 dalam dinamika ketidakseimbangan kelas pada dataset, sekaligus relevan untuk
671 dianalisis secara temporal karena intensitas dan persistensi trafiknya yang khas.

672 Berdasarkan uraian di atas, ketiga kategori serangan yang digunakan dalam penelitian
673 ini, yaitu *Fuzzers*, *Exploits*, dan *Generic*, masing-masing memiliki mekanisme dan
674 karakteristik lalu lintas temporal yang berbeda-beda. Perbedaan tersebut menjadikan
675 pendekatan pemodelan deret waktu dan integrasi skor anomali *Isolation Forest* relevan
676 untuk mendeteksi pola aktivitas jaringan komputer yang menyimpang dari lalu lintas
677 *Normal* secara lebih adaptif (Psychogios et al., 2024; Lim et al., 2021; Liu et al.,
678 2008).

679 5.8 Metrik Evaluasi

680 Evaluasi performa model klasifikasi pada penelitian *Network Intrusion Detection Sys-*
681 *tem* (NIDS) tidak dapat hanya bergantung pada satu metrik tunggal, terutama ketika
682 dataset memiliki distribusi kelas yang tidak seimbang (Wardhani et al., 2019; Owusu-
683 Adjei et al., 2023). Titik awal evaluasi tersebut adalah *confusion matrix*, yaitu tabel
684 yang menggambarkan hubungan antara label kelas aktual dengan hasil prediksi mo-
685 del secara sistematis (Wardhani et al., 2019). Dalam konteks IDS, *confusion matrix*
686 mendefinisikan empat komponen dasar yang menjadi landasan perhitungan metrik
687 evaluasi. *True Positive* (TP) menyatakan jumlah lalu lintas serangan yang berhasil
688 dikenali sebagai serangan oleh model, sedangkan *True Negative* (TN) menyatakan
689 jumlah lalu lintas normal yang berhasil dikenali sebagai normal. Sebaliknya, *False*
690 *Positive* (FP) terjadi ketika lalu lintas normal salah diklasifikasikan sebagai serangan
691 atau *false alarm*, sedangkan *False Negative* (FN) terjadi ketika lalu lintas serangan
692 gagal dideteksi dan diklasifikasikan sebagai lalu lintas normal atau *missed detection*.
693 Pada klasifikasi multikelas, *confusion matrix* diperluas menjadi matriks berukuran
694 $K \times K$ dengan K menyatakan jumlah kelas, sehingga pola kesalahan klasifikasi an-
695 tar kategori serangan dapat dianalisis secara lebih terperinci (Riyanto et al., 2023).
696 Untuk menghitung metrik berbasis TP, TN, FP, dan FN pada kasus multikelas, se-
697 tiap kelas dapat diperlakukan sebagai kelas positif secara bergantian, sedangkan kelas
698 lainnya diperlakukan sebagai kelas negatif melalui pendekatan *one-vs-rest*. Keempat
699 komponen tersebut menjadi dasar perhitungan metrik-metrik berikut.

700 Pada kondisi *imbalanced dataset*, model dapat memperoleh nilai akurasi tinggi hanya
701 dengan memprediksi kelas mayoritas secara dominan meskipun gagal mengenali se-
702 bagian besar kelas minoritas (Owusu-Adjei et al., 2023). Oleh karena itu, penelitian
703 ini menggunakan beberapa metrik evaluasi yang saling melengkapi, yaitu akurasi, pre-
704 sisi, *recall*, F1-score, dan *False Alarm Rate* (FAR). Kombinasi metrik tersebut mem-
705 berikan gambaran performa model yang lebih representatif, khususnya pada skenario

klasifikasi multikelas dengan distribusi data yang tidak seimbang (Riyanto et al., 2023; Chinnasamy et al., 2025).

5.8.1 Akurasi

Akurasi merupakan metrik evaluasi yang menunjukkan proporsi total prediksi yang berhasil diklasifikasikan dengan benar terhadap seluruh data pengujian (Wardhani et al., 2019). Nilai akurasi dihitung menggunakan Persamaan 7.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (7)$$

Pada Persamaan 7, pembilang $TP + TN$ merupakan jumlah seluruh prediksi yang benar, baik untuk kelas serangan maupun kelas normal, sedangkan penyebut $TP + TN + FP + FN$ merupakan total seluruh data pengujian. Metrik ini banyak digunakan karena sederhana dan mudah diinterpretasikan. Namun, pada dataset dengan distribusi kelas yang tidak seimbang, akurasi sering kali memberikan gambaran performa yang menyesatkan (Owusu-Adjei et al., 2023). Sebagai contoh, model dapat memperoleh nilai akurasi tinggi hanya karena berhasil mengenali kelas mayoritas, meskipun nilai FN terhadap kelas serangan minoritas tetap sangat besar. Oleh karena itu, evaluasi IDS modern memerlukan metrik tambahan seperti presisi, *recall*, dan F1-score agar performa model dapat dianalisis secara lebih representatif (Wardhani et al., 2019).

5.8.2 Presisi dan *Recall*

Presisi (*precision*) menunjukkan proporsi prediksi positif yang benar-benar merupakan kelas positif, sedangkan *recall* menunjukkan kemampuan model dalam mendeteksi seluruh data positif yang sebenarnya (Wardhani et al., 2019). Nilai presisi dan *recall* dihitung masing-masing menggunakan Persamaan 8 dan Persamaan 9.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (8)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (9)$$

Pada Persamaan 8, presisi dihitung sebagai rasio antara TP terhadap jumlah seluruh prediksi positif, yaitu $TP + FP$. Nilai presisi yang tinggi mengindikasikan bahwa sebagian besar alarm yang dihasilkan model benar-benar merupakan serangan, bukan lalu lintas normal yang salah terklasifikasi. Pada Persamaan 9, *recall* dihitung sebagai rasio antara TP terhadap jumlah seluruh data positif aktual, yaitu $TP + FN$. Nilai *recall* yang tinggi menunjukkan kemampuan model dalam mendeteksi sebanyak mungkin aktivitas serangan yang sebenarnya. Dalam konteks dataset tidak seimbang, terdapat *trade-off* antara presisi dan *recall*. Model dengan *recall* tinggi cenderung lebih agresif dalam menghasilkan prediksi positif sehingga FP meningkat dan presisi menurun, sementara model dengan presisi tinggi cenderung lebih selektif namun berpotensi melewatkan serangan aktual sehingga FN meningkat (Owusu-Adjei et al., 2023). Pada kelas serangan minoritas, nilai *recall* yang rendah mengindikasikan bahwa sebagian besar serangan tersebut

742 terabaikan, sehingga kedua metrik ini perlu dianalisis secara bersamaan (Riyanto
743 et al., 2023).

744 5.8.3 *F1-Score*

745 F1-score merupakan rata-rata harmonik antara presisi dan *recall* yang digunakan
746 untuk menyeimbangkan kedua metrik tersebut (Wardhani et al., 2019). Nilai
747 F1-score dihitung menggunakan Persamaan 10.

$$F1 = \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (10)$$

748 Pada Persamaan 10, rata-rata harmonik digunakan sebagai pengganti rata-rata
749 aritmetika karena lebih sensitif terhadap nilai ekstrem. Apabila salah satu antara
750 presisi atau *recall* bernilai sangat rendah, nilai F1-score akan tertekan secara sig-
751 nifikan meskipun metrik yang lain tinggi. Pada dataset tidak seimbang, F1-score
752 dianggap lebih representatif dibandingkan akurasi karena mempertimbangkan ke-
753 mampuan model dalam mendeteksi kelas minoritas sekaligus mengontrol kesala-
754 han prediksi positif (Owusu-Adjei et al., 2023; Riyanto et al., 2023). Dalam klasi-
755 fikasi multikelas, F1-score umumnya dihitung menggunakan pendekatan agregasi
756 seperti F1 *macro* dan F1 *weighted*. F1 *macro* menghitung rata-rata F1-score
757 setiap kelas tanpa mempertimbangkan ukuran kelas, sebagaimana ditunjukkan
758 pada Persamaan 11.

$$F1_{\text{macro}} = \frac{1}{K} \sum_{k=1}^K F1_k \quad (11)$$

759 Pada Persamaan 11, K menyatakan jumlah kelas dan $F1_k$ menyatakan nilai F1-
760 score pada kelas ke- k . Karena setiap kelas diberi bobot yang sama, F1 *macro*
761 lebih sensitif terhadap performa pada kelas serangan minoritas. Sementara itu,
762 F1 *weighted* mempertimbangkan proporsi jumlah data pada masing-masing kelas,
763 sebagaimana ditunjukkan pada Persamaan 12.

$$F1_{\text{weighted}} = \sum_{k=1}^K \frac{n_k}{N} F1_k \quad (12)$$

764 Pada Persamaan 12, n_k menyatakan jumlah sampel pada kelas ke- k , sedangkan
765 N menyatakan total seluruh sampel. Karena memperhitungkan ukuran kelas,
766 F1 *weighted* lebih dipengaruhi oleh performa pada kelas mayoritas. Penggunaan
767 F1 *macro* dan F1 *weighted* secara bersamaan memungkinkan evaluasi performa
768 model yang lebih komprehensif (Riyanto et al., 2023).

769 5.8.4 *False Alarm Rate (FAR)*

770 *False Alarm Rate (FAR)* merupakan metrik yang mengukur proporsi lalu lintas
771 normal yang salah diklasifikasikan sebagai serangan terhadap seluruh data normal
772 (Wardhani et al., 2019). Nilai FAR dihitung menggunakan Persamaan 13.

$$\text{FAR} = \frac{FP}{FP + TN} \quad (13)$$

773 Pada Persamaan 13, FP menyatakan jumlah lalu lintas normal yang salah terk-

lasifikasi sebagai serangan, sedangkan $FP + TN$ merupakan total seluruh lalu lintas normal dalam data pengujian. Dalam konteks operasional IDS, FAR yang tinggi menunjukkan bahwa sistem terlalu sering menghasilkan alarm palsu terhadap lalu lintas normal. Kondisi ini dapat membebani administrator jaringan komputer dengan terlalu banyak peringatan yang tidak benar, menurunkan kepercayaan terhadap sistem, dan berisiko membuat aktivitas serangan yang sebenarnya kurang diperhatikan (Chinnasamy et al., 2025). Oleh karena itu, selain meningkatkan kemampuan deteksi terhadap serangan, model IDS juga perlu mempertahankan nilai FAR serendah mungkin agar tetap efektif pada lingkungan jaringan komputer nyata.


Dalam penelitian ini, FAR dihitung dengan pendekatan agregasi *Normal-vs-Attack*. Kelas Normal diperlakukan sebagai kelas negatif, sedangkan Generic, Exploits, dan Fuzzers digabungkan sebagai kelas serangan. Dengan demikian, *false alarm* terjadi ketika lalu lintas Normal diklasifikasikan sebagai salah satu kelas serangan. Kesalahan klasifikasi antar kelas serangan, misalnya Generic yang diklasifikasikan sebagai Exploits, tidak dihitung sebagai FAR, tetapi tetap tercermin pada *confusion matrix* multikelas. Secara khusus, pada skema agregasi ini, TN didefinisikan sebagai jumlah sampel Normal yang diprediksi sebagai Normal, sedangkan FP didefinisikan sebagai jumlah sampel Normal yang diprediksi sebagai salah satu kelas serangan, yaitu Generic, Exploits, atau Fuzzers. Kesalahan klasifikasi antar kelas serangan tidak menambah nilai FP dalam perhitungan FAR, tetapi tetap dianalisis melalui *confusion matrix* multikelas.

6 Langkah kerja

Judul: Sistem Deteksi Intrusi Jaringan Komputer Menggunakan *Temporal Fusion Transformer* dengan Integrasi Skor Anomali *Isolation Forest*

Kata kunci: *deep learning, intrusion detection system, cybersecurity, Isolation Forest, Temporal Fusion Transformer*

Langkah kerja:



Gambar 2: Diagram alur langkah kerja penelitian.

Diagram alur langkah kerja penelitian secara keseluruhan ditunjukkan pada Gambar 2. Setiap tahapan dalam diagram tersebut diuraikan secara rinci sebagai berikut.

- 804 a. Melakukan studi literatur untuk mempelajari konsep dan karakteristik komponen
805 utama penelitian, meliputi arsitektur *Temporal Fusion Transformer* (Lim et al., 2021),
806 mekanisme *Isolation Forest* sebagai penghasil skor anomali (Liu et al., 2008), pen-
807 dekatan pemodelan deret waktu dengan *sliding window* (Psychogyios et al., 2024),
808 penanganan ketidakseimbangan kelas pada dataset IDS, serta penelitian serupa seba-
809 gai referensi (Chinnasamy et al., 2025; Sajid et al., 2024).
- 810 b. Melakukan pengumpulan data dengan memuat keempat file dataset UNSW-NB15
811 (UNSW-NB15_1.csv hingga UNSW-NB15_4.csv) dan memahami struktur fitur ber-
812 dasarkan dokumen UNSW-NB15_features.csv (Moustafa & Slay, 2015).
- 813 c. Melakukan eksplorasi dan visualisasi data.
- 814 i. Melakukan analisis distribusi kelas pada keempat kelas yang digunakan dalam
815 penelitian (*Normal*, *Generic*, *Exploits*, dan *Fuzzers*).
- 816 ii. Menganalisis derajat ketidakseimbangan kelas (*class imbalance*) dan mengevalu-
817 asi kebutuhan intervensi balancing berdasarkan rasio distribusi antar kelas.
- 818 iii. Melakukan pengecekan nilai *null*, *infinity*, dan duplikat pada data.
- 819 iv. Menampilkan analisis deskriptif keseluruhan dataset.
- 820 v. Menampilkan analisis deskriptif per kategori kelas untuk melihat karakteristik
821 antar kelas.
- 822 vi. Menampilkan visualisasi histogram dan *density plot* untuk melihat distribusi fitur.
- 823 vii. Menampilkan visualisasi *box plot* untuk mendeteksi *outlier* pada data.
- 824 viii. Menampilkan visualisasi *heatmap* korelasi antar variabel numerik.
- 825 ix. Menampilkan visualisasi *bar chart* distribusi kelas untuk memvisualisasikan tingkat
826 ketidakseimbangan secara eksplisit.
- 827 d. Melakukan praproses data.
- 828 i. Melakukan penyaringan dataset untuk mempertahankan hanya rekaman yang
829 termasuk dalam empat kelas penelitian (*Normal*, *Generic*, *Exploits*, *Fuzzers*).
- 830 ii. Melakukan pembersihan data awal, meliputi penghapusan atau imputasi nilai
831 *null* dan *infinity*, serta penghapusan baris duplikat pada data.
- 832 iii. Melakukan pengurutan data secara kronologis berdasarkan *timestamp* untuk rekon-
833 struksi deret waktu yang koheren.
- 834 iv. Melakukan pembagian data secara kronologis menjadi data latih, validasi, dan uji
835 tanpa *random shuffle*, dengan rasio yang ditentukan melalui eksperimen, misalnya
836 70:15:15 atau 80:10:10. Data validasi digunakan untuk pemilihan *hyperparameter*
837 dan *early stopping*, sedangkan data uji hanya digunakan pada tahap evaluasi akhir
838 agar hasil pengujian tidak bias terhadap proses *tuning*.
- 839 v. Melakukan *encoding* fitur kategorikal (*proto*, *service*, *state*) dengan parameter
840 yang hanya di-fit pada data latih, kemudian diterapkan pada data validasi dan
841 data uji.

- 842 vi. Melakukan normalisasi Min-Max pada seluruh fitur numerik dengan parameter
843 minimum dan maksimum yang hanya dihitung dari data latih, kemudian diter-
844 apkan pada data validasi dan data uji.
- 845 vii. Untuk mencegah kebocoran data (*data leakage*), data validasi dan data uji tidak
846 digunakan dalam proses pembentukan parameter *preprocessing*, penanganan keti-
847 dakseimbangan kelas, maupun pelatihan model tambahan seperti *Isolation For-*
848 *est*.
- 849 e. Melakukan analisis dan penanganan ketidakseimbangan kelas.
- 850 i. Melakukan eksperimen awal menggunakan data asli tanpa intervensi balancing
851 untuk memperoleh *baseline* performa model pada kondisi data tidak seimbang.
- 852 ii. Menentukan strategi balancing yang akan diterapkan berdasarkan hasil analisis
853 distribusi kelas pada data latih.
- 854 iii. Menerapkan teknik balancing yang dipilih hanya pada data latih. Strategi utama
855 yang diprioritaskan adalah *class weighting* karena tidak mengubah struktur tem-
856 poral data. Teknik oversampling atau undersampling hanya digunakan sebagai
857 eksperimen pembandingan apabila penerapannya tidak mengganggu struktur tem-
858 poral data latih.
- 859 iv. Mengevaluasi dampak balancing terhadap distribusi data latih dan memband-
860 ingkan performa model sebelum dan sesudah intervensi balancing menggunakan
861 metrik presisi, *recall*, dan F1-score per kelas.
- 862 f. Mengintegrasikan *Isolation Forest* sebagai penghasil skor anomali.
- 863 i. Melatih model *Isolation Forest* secara *unsupervised* hanya pada subset kelas Nor-
864 mal dalam data latih, sehingga skor anomali yang dihasilkan merepresentasikan
865 tingkat penyimpangan suatu sampel terhadap pola lalu lintas normal.
- 866 ii. Menentukan parameter konfigurasi seperti `n_estimators`, `max_samples`, dan `random_state`.
867 Parameter `contamination`, apabila digunakan, hanya berperan dalam penentuan
868 ambang keputusan anomali, sedangkan penelitian ini memanfaatkan skor anomali
869 kontinu sebagai fitur tambahan.
- 870 iii. Menghitung skor anomali untuk setiap *instance* pada data latih, validasi, dan
871 uji menggunakan model *Isolation Forest* yang telah dilatih hanya pada subset
872 Normal dalam data latih.
- 873 iv. Mengintegrasikan skor anomali sebagai fitur tambahan (fitur ke- $F + 1$) pada se-
874 tiap titik waktu, sehingga model tidak hanya mempelajari pola temporal dari
875 fitur jaringan komputer mentah tetapi juga mempertimbangkan derajat ketida-
876 knormalan secara eksplisit.
- 877 g. Melakukan konversi data ke format deret waktu menggunakan pendekatan *sliding win-*
878 *dow*.
- 879 i. Membentuk sekuens input dengan panjang jendela historis W berdasarkan para-
880 meter yang ditentukan melalui eksperimen.
- 881 ii. Menentukan panjang jendela target T sebagai output yang akan dimodelkan.

- 882 iii. Membentuk *sliding window* secara terpisah pada data latih, validasi, dan uji agar
- 883 tidak ada sekuens yang melintasi batas antar subset data.
- 884 iv. Pembentukan *sliding window* juga mempertimbangkan batas antar file CSV atau
- 885 segmen data agar tidak membentuk sekuens yang tidak memiliki kontinuitas tem-
- 886 poral.
- 887 v. Melakukan eksperimen ablasi untuk menentukan kombinasi W , T , dan rasio pem-
- 888 bagian data yang optimal.
- 889 h. Membangun dan melatih model *Temporal Fusion Transformer* (TFT) dalam dua kon-
- 890 figurasi yang dibandingkan secara paralel.
 - 891 i. Melakukan konfigurasi arsitektur TFT, meliputi *encoder length*, *prediction length*,
 - 892 dan *hidden size*.
 - 893 ii. Melatih TFT-base: model TFT menggunakan fitur jaringan komputer non-target
 - 894 hasil praproses, tanpa integrasi skor anomali *Isolation Forest*, sebagai kondisi
 - 895 kontrol.
 - 896 iii. Melatih TFT-IF: model TFT menggunakan fitur jaringan komputer non-target
 - 897 hasil praproses beserta skor anomali *Isolation Forest* sebagai fitur tambahan ke-
 - 898 ($F + 1$).
 - 899 iv. Melatih model dengan fungsi *loss* yang sesuai untuk klasifikasi multikelas dan
 - 900 *optimizer Adam*.
 - 901 v. Mengimplementasikan *learning rate scheduler* selama proses pelatihan.
 - 902 vi. Melakukan validasi model secara berkala menggunakan data validasi untuk me-
 - 903 mantau konvergensi, menerapkan *early stopping*, dan membantu pemilihan kon-
 - 904 figurasi *hyperparameter*.
 - 905 i. Melakukan evaluasi performa model.
 - 906 i. Mengevaluasi performa TFT-base dan TFT-IF pada skenario klasifikasi empat
 - 907 kelas (*Normal*, *Generic*, *Exploits*, *Fuzzers*).
 - 908 ii. Membandingkan performa masing-masing model pada data asli (tanpa balancing)
 - 909 dengan data setelah intervensi balancing menggunakan metrik yang sama.
 - 910 iii. Menghitung metrik evaluasi: akurasi, presisi, *recall*, F1-score (*macro* dan *weighted*),
 - 911 dan *false alarm rate* (FAR).
 - 912 iv. Menampilkan *confusion matrix* untuk melihat distribusi kesalahan prediksi antar
 - 913 kelas per model.
 - 914 v. Membandingkan performa TFT-base dan TFT-IF menggunakan seluruh metrik
 - 915 di atas untuk menguji hipotesis utama penelitian, yaitu bahwa integrasi skor
 - 916 anomali *Isolation Forest* sebagai fitur tambahan meningkatkan performa sistem
 - 917 deteksi intrusi dibandingkan model tanpa fitur anomali.
 - 918 j. Melakukan analisis interpretabilitas model.
 - 919 i. Mengekstraksi *feature importance* dari *Variable Selection Network* (VSN) milik
 - 920 TFT untuk mengidentifikasi fitur yang paling berpengaruh terhadap prediksi.

- 921 ii. Apabila hasil interpretabilitas menunjukkan subset fitur yang konsisten dominan,
 922 penelitian dapat melakukan eksperimen tambahan berupa pelatihan ulang model
 923 TFT menggunakan fitur terpilih dari VSN. Eksperimen ini bersifat pendukung
 924 dan tidak menjadi fokus utama evaluasi.
- 925 iii. Menganalisis *attention weight* untuk memahami pola temporal yang paling rele-
 926 van.
- 927 iv. Menganalisis kontribusi skor anomali IF sebagai fitur tambahan terhadap ke-
 928 mampuan model dalam membedakan berbagai kategori serangan dari lalu lintas
 929 normal.
- 930 v. Membuat visualisasi fitur dan *timestep* paling berpengaruh.
- 931 k. Menyusun bagian "Hasil dan Pembahasan" pada dokumen skripsi.
- 932 l. Menyusun bagian "Kesimpulan" pada dokumen skripsi.
- 933 m. Menyusun bagian "Abstrak" pada dokumen skripsi.
- 934 n. Melakukan *final check* untuk dokumen skripsi.
- 935 o. Melakukan uji Turnitin untuk dokumen skripsi.
- 936 p. Merevisi dokumen skripsi (apabila tidak lolos uji Turnitin).
- 937 q. Mempersiapkan dokumen dan melakukan pendaftaran sidang skripsi.
- 938 r. Melaksanakan sidang skripsi.
- 939 Langkah-langkah di atas secara umum bersifat sekuensial, mulai dari studi literatur
 940 hingga pelaksanaan sidang skripsi. Tahapan yang harus dilakukan secara berurutan meliputi
 941 studi literatur, pengumpulan data, eksplorasi dan visualisasi data, praproses data, anali-
 942 sis ketidakseimbangan data latih, integrasi skor anomali *Isolation Forest*, konversi data ke
 943 bentuk deret waktu, pelatihan model, evaluasi model, analisis interpretabilitas, penulisan
 944 skripsi, uji Turnitin, pendaftaran sidang, dan pelaksanaan sidang skripsi. Urutan terse-
 945 but perlu dipertahankan karena setiap tahap menghasilkan keluaran yang menjadi masukan
 946 bagi tahap berikutnya, misalnya hasil praproses diperlukan sebelum analisis imbalance dan
 947 pembentukan skor anomali, sedangkan hasil konversi deret waktu diperlukan sebelum model
 948 TFT dapat dilatih.
- 949 Namun demikian, beberapa tahapan dalam alur penelitian ini bersifat iteratif. Analisis
 950 dan pemilihan strategi penanganan imbalance dapat dilakukan berulang apabila distribusi
 951 data latih atau performa model pada kelas minoritas belum memadai. Eksperimen pada
 952 tahap konversi deret waktu juga dapat memerlukan penyesuaian parameter panjang historis
 953 W dan panjang target T secara berulang untuk memperoleh konfigurasi yang paling sesuai.
 954 Selain itu, tahap analisis interpretabilitas melalui VSN dan *attention weight* dapat meng-
 955 hasilkan pemilihan fitur yang kemudian digunakan untuk melatih ulang model TFT. Dengan
 956 demikian, bagian iteratif dalam penelitian ini terutama terletak pada pemilihan strategi bal-
 957 ancing, penyesuaian parameter *sliding window*, serta pelatihan ulang model berbasis fitur
 958 terpilih dari VSN apabila hasil perbandingan model belum konklusif.

959 7 Jadwal penelitian

960 Mengacu kepada langkah kerja penelitian yang telah diuraikan sebelumnya, untuk melakukan
 961 penelitian secara efisien dan terstruktur, maka berikut disusun rencana jadwal penelitian
 962 berdasarkan alokasi waktu yang tersedia. Jadwal penelitian ini memuat tahapan-tahapan
 963 kegiatan mulai dari studi literatur, pengolahan dan analisis data, pembangunan model,
 964 evaluasi, hingga penyusunan dokumen skripsi dan pelaksanaan sidang.

Tabel 4: Rencana Penelitian

No.	Kegiatan	Mei				Juni				Juli				Agustus				September				Oktober				November				Desember			
		1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4	1	2	3	4				
1	Melakukan studi literatur	v	v	v	v	v	v																										
2	Melakukan pengumpulan data		v	v	v																												
3	Melakukan eksplorasi dan visualisasi data				v	v	v																										
4	Melakukan praproses data					v	v	v																									
5	Melakukan analisis dan penanganan ketidakseimbangan kelas						v	v	v																								
6	Mengintegrasikan <i>Isolation Forest</i>						v	v	v																								
7	Melakukan konversi ke format deret waktu									v	v	v																					
8	Membangun dan melatih model TFT dengan dan tanpa skor anomali									v	v	v	v																				
9	Melakukan evaluasi performa model												v	v	v																		
10	Melakukan analisis interpretabilitas												v	v	v																		
11	Menyusun bagian "Hasil dan Pembahasan" pada dokumen skripsi															v	v	v															
12	Menyusun bagian "Kesimpulan" pada dokumen skripsi																v	v	v														
13	Menyusun bagian "Abstrak" pada dokumen skripsi																	v	v	v													
14	Melakukan <i>final check</i> untuk dokumen skripsi																	v	v	v	v												
15	Melakukan uji Turnitin untuk dokumen skripsi																	v	v	v	v												
16	Merevisi dokumen skripsi apabila tidak lolos uji Turnitin																		v	v		v	v	v									
17	Mempersiapkan dokumen dan melakukan pendaftaran sidang skripsi																					v	v	v	v								
18	Melaksanakan sidang skripsi																									v	v	v	v				

965 Daftar Pustaka

- 966 Aleesa, A. M., Zaidan, B. B., Zaidan, A. A., & Sahar, N. M. (2020). Review of intrusion
967 detection systems based on deep learning techniques: coherent taxonomy, challenges, mo-
968 tivations, recommendations, substantial analysis and future directions. *Neural Computing*
969 *and Applications*, 32, 9827–9858. <https://doi.org/10.1007/s00521-019-04557-3>
- 970 Alkasassbeh, M. & Baddar, S. A.-H. (2023). Intrusion Detection Systems: A State-of-the-
971 Art Taxonomy and Survey. *Arabian Journal for Science and Engineering*, 48. <https://doi.org/10.1007/s13369-022-07412-1>
- 972
- 973 Alsariera, Y. A. (2022). Detecting block ciphers generic attacks: An instance-based machine
974 learning method. *International Journal of Advanced and Applied Sciences*, 9, 60–68.
975 <https://doi.org/10.21833/ijaas.2022.05.007>
- 976 Alsoufi, M. A., Razak, S., Siraj, M. M., Nafea, I., Ghaleb, F. A., Saeed, F., & Nasser,
977 M. (2021). *Anomaly-based intrusion detection systems in iot using deep learning: A*
978 *systematic literature review*. <https://doi.org/10.3390/app11188383>
- 979 Altalhan, M., Algarni, A., & Alouane, M. T.-H. (2025). Imbalanced Data Problem in
980 Machine Learning: A Review. *IEEE Access*, 13, 13686–13699. <https://doi.org/10.1109/ACCESS.2025.3531662>
- 981
- 982 Ayhan, B., Vargo, E. P., & Tang, H. (2024). On the Exploration of Temporal Fusion Trans-
983 formers for Anomaly Detection with Multivariate Aviation Time-Series Data. *Aerospace*,
984 11, 1–18. <https://doi.org/10.3390/aerospace11080646>
- 985 Badan Siber dan Sandi Negara (BSSN) / Id-SIRTII/CC Direktorat Operasi Keamanan
986 Siber (2024). Lanskap Keamanan Siber Indonesia 2024. Technical report, Badan Siber
987 dan Sandi Negara (BSSN).
- 988 BAKIRARAR, B. & ELHAN, A. H. (2023). Class Weighting Technique to Deal with Imbal-
989 anced Class Problem in Machine Learning: Methodological Research. *Turkiye Klinikleri*
990 *Journal of Biostatistics*, 15, 19–29. <https://doi.org/10.5336/biostatic.2022-93961>
- 991 Cai, J., Zou, P., Xiong, D., & He, J. (2015). A Guided Fuzzing Approach for Security
992 Testing of Network Protocol Software. *2015 6th IEEE International Conference on Soft-*
993 *ware Engineering and Service Science (ICSESS)*, 726–729. <https://doi.org/10.1109/ICSESS.2015.7339160>
- 994
- 995 Carvalho, M., Pinho, A. J., & Brás, S. (2025). Resampling approaches to handle class
996 imbalance: a review from a data perspective. *Journal of Big Data*, 12. <https://doi.org/10.1186/s40537-025-01119-4>
- 997
- 998 Chinnasamy, R., Subramanian, M., Easwaramoorthy, S. V., & Cho, J. (2025). Deep learning-
999 driven methods for network-based intrusion detection systems: A systematic review. *ICT*
1000 *Express*, 11, 181–215. <https://doi.org/10.1016/j.icte.2025.01.005>
- 1001 Faouzi, J. (2024). *Time Series Classification: A Review of Algorithms and Implementations*.
1002 IntechOpen. <https://doi.org/10.5772/intechopen.1004810>

1003 Hamilton, J. D. (1994). *Time Series Analysis James D. Hamilton*. Princeton University
1004 Press.

1005 James, P. A. & Co (1980). Computer Security Threat Monitoring and Surveillance. Technical
1006 report, James P. Anderson Co.

1007 Joshi, P. & Gurusamy, M. (2025). Time Series Based Network Intrusion Detection using
1008 MTF-Aided Transformer. Technical report, Department of Electrical and Computer En-
1009 gineering, National University of Singapore. <http://arxiv.org/abs/2508.16035>

1010 Kijsanayothin, P. & Hewett, R. (2013). Exploit-based analysis of attack models. *Proceedings*
1011 *- IEEE 12th International Symposium on Network Computing and Applications, NCA*
1012 *2013*, 183–186. <https://doi.org/10.1109/NCA.2013.18>

1013 Kothamali, P. R. & Banik, S. (2022). REVISTA DE INTELIGENCIA ARTIFICIAL EN
1014 MEDICINA Limitations of Signature-Based Threat Detection. *Revista de Inteligencia*
1015 *Artificial en Medicina*, 13, 381–391. <https://redcrevistas.com/index.php/Revista>

1016 Kuzior, A., Tiutiunyk, I., Zielińska, A., & Kelemen, R. (2024). Cybersecurity and cy-
1017 bercrime: Current trends and threats. *Journal of International Studies*, 17, 220–239.
1018 <https://doi.org/10.14254/2071-8330.2024/17-2/12>

1019 Lim, B., Arik, S. O., Loeff, N., & Pfister, T. (2021). Temporal Fusion Transformers for
1020 Interpretable Multi-horizon Time Series Forecasting. *International Journal of Forecasting*,
1021 37, 1748–1764. <http://arxiv.org/abs/1912.09363>

1022 Lim, B. & Zohren, S. (2021). Time-series forecasting with deep learning: A survey. *Philo-*
1023 *sophical Transactions of the Royal Society A: Mathematical, Physical and Engineering*
1024 *Sciences*, 379, 1–14. <https://doi.org/10.1098/rsta.2020.0209>

1025 Liu, F. T., Ting, K. M., & Zhou, Z. H. (2008). Isolation forest. *Proceedings - IEEE*
1026 *International Conference on Data Mining, ICDM*, 413–422. [https://doi.org/10.1109/](https://doi.org/10.1109/ICDM.2008.17)
1027 [ICDM.2008.17](https://doi.org/10.1109/ICDM.2008.17)

1028 Liu, F. T., Ting, K. M., & Zhou, Z. H. (2012). Isolation-based anomaly detection. *ACM*
1029 *Transactions on Knowledge Discovery from Data*, 6, 1–39. [https://doi.org/10.1145/](https://doi.org/10.1145/2133360.2133363)
1030 [2133360.2133363](https://doi.org/10.1145/2133360.2133363)

1031 McNally, R., Yiu, K., Grove, D., & Gerhardy, D. (2012). Fuzzing: The State of the Art.
1032 Technical report, Defence Science and Technology Organisation.

1033 Monte, M. (2015). Network Attacks & Exploitation: A Framework. Technical report, John
1034 Wiley & Sons, Inc. www.it-ebooks.info

1035 Moustafa, N. & Slay, J. (2015). UNSW-NB15: A Comprehensive Data set for Network Intru-
1036 sion Detection systems (UNSW-NB15 Network Data Set). *2015 Military Communications*
1037 *and Information Systems Conference (MilCIS)*. <https://cve.mitre.org/>

1038 Moustafa, N. & Slay, J. (2016). The evaluation of Network Anomaly Detection Systems:
1039 Statistical analysis of the UNSW-NB15 data set and the comparison with the KDD99 data
1040 set. *Information Security Journal*, 25, 18–31. [https://doi.org/10.1080/19393555.](https://doi.org/10.1080/19393555.2015.1125974)
1041 [2015.1125974](https://doi.org/10.1080/19393555.2015.1125974)

1042 Owusu-Adjei, M., Hayfron-Acquah, J. B., Frimpong, T., & Abdul-Salaam, G. (2023). Im-
1043 balanced class distribution and performance evaluation metrics: A systematic review of
1044 prediction accuracy for determining model performance in healthcare systems. *PLOS*
1045 *Digital Health*, 2, 1–19. <https://doi.org/10.1371/journal.pdig.0000290>

1046 Psychogyios, K., Papadakis, A., Bourou, S., Nikolaou, N., Maniatis, A., & Zahariadis, T.
1047 (2024). Deep Learning for Intrusion Detection Systems (IDSs) in Time Series Data †.
1048 *Future Internet*, 16. <https://doi.org/10.3390/fi16030073>

1049 Riyanto, S., Sitanggang, I. S., Djatna, T., & Atikah, T. D. (2023). Comparative Analysis
1050 using Various Performance Metrics in Imbalanced Data for Multi-class Text Classification.
1051 *International Journal of Advanced Computer Science and Applications*, 14, 1089–1090.
1052 <https://doi.org/10.14569/IJACSA.2023.01406116>

1053 Sajid, M., Malik, K. R., Almogren, A., Malik, T. S., Khan, A. H., Tanveer, J., &
1054 Rehman, A. U. (2024). Enhancing intrusion detection: a hybrid machine and deep
1055 learning approach. *Journal of Cloud Computing*, 13. <https://doi.org/10.1186/s13677-024-00685-x>

1057 Su, L., Zuo, X., Li, R., Wang, X., Zhao, H., & Huang, B. (2025). A systematic review for
1058 transformer-based long-term series forecasting. *Artificial Intelligence Review*, 58. <https://doi.org/10.1007/s10462-024-11044-2>

1060 Sviatun, O. V., Goncharuk, O. V., Chernysh, R., Kuzmenko, O., & Kozych, I. V. (2021).
1061 Combating cybercrime: Economic and legal aspects. *WSEAS Transactions on Business*
1062 *and Economics*, 18, 751–762. <https://doi.org/10.37394/23207.2021.18.72>

1063 Vaswani, A., Brain, G., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N.,
1064 Łukasz Kaiser, & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural*
1065 *Information Processing Systems 30 / 31st Conference on Neural Information Processing*
1066 *Systems (NIPS 2017)*, 5998–6008.

1067 Wardhani, N. W. S., Sulistyono, A. D., Rochayani, M. Y., Lestantyo, P., & Iriany, A. (2019).
1068 Cross-validation Metrics for Evaluating Classification Performance on Imbalanced Data.
1069 *2019 International Conference on Computer, Control, Informatics and its Applications*,
1070 14–18.

1071 Wen, Q., Zhou, T., Zhang, C., Chen, W., Ma, Z., Yan, J., & Sun, L. (2023). Transformers
1072 in Time Series: A Survey. Technical report, DAMO Academy, Alibaba Group; Shanghai
1073 Jiao Tong University. <http://arxiv.org/abs/2202.07125>

1074 Zahoor, A., Abbasi, W., Babar, M. Z., & Aljohani, A. (2025). Robust IoT security using
1075 isolation forest and one class SVM algorithms. *Scientific Reports*, 15. <https://doi.org/10.1038/s41598-025-20445-4>

1077 Zoghi, Z. & Serpen, G. (2021). UNSW-NB15 Computer Security Dataset: Analysis through
1078 Visualization. Technical report, Electrical Engineering & Computer Science, Univer-
1079 sity of Toledo, Ohio, USA. [https://www.unsw.adfa.edu.au/unsw-canberra-cyber/](https://www.unsw.adfa.edu.au/unsw-canberra-cyber/cybersecurity/ADFA-NB15-Datasets/)
1080 [cybersecurity/ADFA-NB15-Datasets/](https://www.unsw.adfa.edu.au/unsw-canberra-cyber/cybersecurity/ADFA-NB15-Datasets/)